PONTIFÍCIA UNIVERSIDADE CATÓLICA DE GOIÁS
ESCOLA DE CIÊNCIAS EXATAS E DA
COMPUTAÇÃO GRADUAÇÃO EM CIÊNCIA DA
COMPUTAÇÃO

ESTUDO DE ALGORITMOS PARA ANÁLISE DE SENTIMENTOS EM JOGOS ONLINE POR TÓPICOS DE CONVERSAÇÃO

MARCOS ANTÔNIO DA SILVA NASCIMENTO

GOIANIA

2021

MARCOS ANTÔNIO DA SILVA NASCIMENTO

ESTUDO DE ALGORITMOS PARA ANÁLISE DE SENTIMENTOS EM JOGOS ONLINE POR TÓPICOS DE CONVERSAÇÃO

Trabalho de Conclusão de Curso apresentado à Escola de Ciências Exatas e da Computação, da Pontifícia Universidade Católica de Goiás, como parte dos requisitos para obtenção do título de Bacharel em Ciência da Computação

Orientador:

Prof. Me. Aníbal Santos Jukemura

Banca Examinadora:

Prof. Me. Fernando Gonçalves Abadia
Prof. Dr. Gustavo Siqueira Vinhal

GOIANIA

2021

MARCOS ANTÔNIO DA SILVA NASCIMENTO

ESTUDO DE ALGORITMOS PARA ANÁLISE DE SENTIMENTOS EM JOGOS ONLINE POR TÓPICOS DE CONVERSAÇÃO

Trabalho de Conclusão de Curso aprovado em sua forma final pela Escola de Ciências Exatas e da Computação, da Pontifícia Universidade Católica de Goiás, para obtenção do título de Bacharel em Ciências da Computação, em _____/_____/_____.

_____
Profa. Ma. Ludmilla Reis Pinheiro dos Santos
Coordenadora de Trabalho de Conclusão de Curso

Banca Examinadora:

_____
Orientador: Prof. Me. Aníbal Santos Jukemura

_____
Prof. Me. Fernando Gonçalves Abadia

_____
Prof. Dr. Gustavo Siqueira Vinhal GOIÂNIA 2019

GOIANIA
2021

AGRADECIMENTOS

Muitas coisas aconteceram no caminho até aqui, coisas boas e ruins. O que todas elas tiveram como semelhança foi o fato que todas elas me levaram adiante, buscando sempre melhorar em algum aspecto, seja ele o de filho, o de estudante ou o de amigo.

Nesse raciocínio, gostaria de agradecer primeiramente e principalmente os meus pais, eles que mesmo com todas as dificuldades deram tudo de si para criar aos meus irmãos e a mim. Eles que em todos os momentos de minha vida acadêmica buscaram me apoiar ao máximo e de todas as formas possíveis.

Gostaria de agradecer também aos meus professores que buscaram me orientar e me preparar para diversas situações, professores estes que me ajudaram a percorrer todo o caminho até aqui.

Adicionalmente, queria agradecer meu orientador, Aníbal Santos Jukemura (“Jukes”), por todas as orientações e toda a paciência, não só nos últimos 10 meses de trabalho, mas pelos últimos anos os quais ele me acompanhou no ensino acadêmico.

Por fim, gostaria de agradecer aos meus amigos, que estiveram comigo durante todo esse tempo, rindo e se desesperando pelas mais diversas situações. Em especial gostaria de agradecer aos meus amigos que caminharam comigo durante grande parte do curso, Gabriel Giani e Paulo Neto, além de todo grupo de amigos da *Ownage*.

RESUMO

Com o crescimento do mundo virtual, os jogos *online* aparecem como uma nova fonte de entretenimento e competição. Dentro desse mundo virtual, onde a identidade do autor pode ser facilmente ocultada, diversos atos de toxidade começaram a se tornar comuns nas comunidades de jogos *online*. Considerando tal cenário, este trabalho avaliou os algoritmos de agrupamento de tópicos, *Latent Dirichlet Allocation* (LDA) e *K-Means*. Através de uma base de dados contendo registros de *chats* de um dos maiores jogos do mundo, os algoritmos foram comparados, a fim de buscar a técnica de agrupamento mais eficiente para a categorização de toxidade dentro dos jogos.

Palavras-chave: *Mineração de Texto; Técnicas de Agrupamento; Jogos Online.*

ABSTRACT

With the growth of the virtual world, online games appear as a new source of entertainment and competition. Within this virtual world, where the author's identity can be easily concealed, several acts of toxicity have started to become common in online gaming communities. Considering this scenario, this work evaluated the topic clustering algorithms, Latent Dirichlet Allocation (LDA) and K-Means. Through a database containing chats records of one of the largest games in the world, the algorithms were compared in order to seek the most efficient clustering technique for the categorization of toxicity within the games.

Keywords: *Text Mining; Clustering Techniques; Online games.*

LISTA DE FIGURAS

Figura 1. Mapa do jogo DotA 2. 17
Figura 2 . Chat de Pings do jogo Dota 2 18
Figura 3. Chat de texto do jogo DotA 2. 18
Figura 4. Comparação entre os tópicos mais e menos presentes para cada emoção 28
Figura 5. Exemplo de WordCloud 36
Figura 6. Exemplo de Gráfico de Barras. 37
Figura 7. Retorno de True para as palavras passadas como referência. 39
Figura 8. Palavras com maiores pesos nas frases da base de aprendizagem. 40
Figura 9. Resultados gerais do agrupamento via LDA. 42
Figura 10. Resultados para o tópico 1 - LDA 43
Figura 11. Resultados para o tópico 2 - LDA 44
Figura 12. Dataframe com as frases e seus respectivos tópicos relacionados. 45
Figura 13. Hiperparâmetros K-Means 46
Figura 14. WordCloud do dataframe estudado. 48
Figura 15. Palavras mais frequentes do dataframe 49
Figura 16. Distribuição dos tópicos no dataframe - LDA 50
Figura 17. Distribuição dos tópicos no dataframe - K-Means. 51

LISTA DE TABELAS

Tabela 1. Tabela da Matriz de Confusão 22
Tabela 2. Distribuição dos tópicos nos grupos 27
Tabela 3. Comparação das performances médias de grupos com/sem a prevalência de um tópico. 27
Tabela 4. Tópicos - LDA 41
Tabela 5. Centroides - K-Means 47
Tabela 6. Palavras com maior relevância em cada tópico - LDA 49
Tabela 7. Palavras com maior relevância em cada tópico - K-Means. 50
Tabela 8. Matriz de Confusão - LDA 52
Tabela 9. Matriz de Confusão - K-Means. 53

SUMÁRIO

1. Introdução 11

2. Conceitos teóricos relevantes 15

2.1. MOBA 15

2.2. DOTA 2 16

2.3. *Machine Learning* 18

2.3.1. Processamento de Linguagem Natural 19

2.3.2. *Topic Models: Latent Dirichlet Allocation* (LDA) 19

2.3.3. *K-Means Clustering* 21

2.3.4. Métricas de Avaliação 22

2.4. Análise de sentimentos 23

3. Trabalhos relacionados 23

3.1. Comportamento tóxico 24

3.2. *Machine Learning* para identificação do Comportamento tóxico em jogos MOBA 26

4. Metodologia de estudo 29

4.1. *Python* 29

4.2. Identificação de comportamento tóxico 34

4.3. Pré-processamento 35

4.4. Processo de Amostragem de Palavras mais frequentes 36

4.5. Processo de *Machine Learning* utilizado nesse trabalho 37

5. Resultados alcançados 47

5.1. Palavras de maior relevância 48

5.2. Discussão de Resultados 51

5.3. Matriz de Confusão 52

6. Conclusão 53

7. BIBLIOGRAFIA 55

APÊNDICE A – Link dos Códigos 61

Apêndice B – Links dos Arquivos 62

1. Introdução

Jogos *online* atualmente são considerados um meio de entretenimento e relaxamento. No Brasil, 82% das pessoas entre 13 e 59 anos jogam em pelo menos um dispositivo (*NPD Group*, 2015) e o mercado de jogos em si não para de crescer. Só no Brasil, o mercado de jogos *online* movimenta por volta de US$ 1.5 bilhões por ano, sendo o 13° maior mercado mundial (LARGHI, 2019).

Nos últimos anos, o mercado de jogos deixou de ser apenas focado em entretenimento e passou a ser visto também de forma profissional. Várias companhias começaram a montar times para competição em jogos que movimentam e premiam seus jogadores com milhares de dólares anualmente. (Confederação Brasileira de *eSports* – CbeSports, c2017)

Um dos gêneros de jogos mais populares atualmente é o MOBA (*Multiplayer Online Battle Arena*). Os principais jogos dessa categoria são o *League of Legends* (LoL) e o *Defense of the Ancients 2* (DotA *2)*. Ambos contam com torneios anuais e até mesmo semestrais, com premiações que passam dos US$ 177 milhões por ano, no caso do *DotA 2.* (GUERRA, 2019)

Diferente de alguns estilos de jogos, o gênero MOBA é altamente competitivo, uma vez que a vitória nesse estilo depende de um trabalho em equipe eficiente e de estratégias bem definidas (NETO, 2019). Para isso, os jogadores usam o *chat* de texto ou o *chat* de voz (caso o jogo dê suporte) e durante essas conversas, vários tipos de interações ou de expressão de sentimentos podem surgir, sendo infelizmente, nem todas positivas.

Ainda no contexto sobre o gênero MOBA, utilizando as ações de uma pessoa durante uma partida *online* como base do estudo, a Análise de Sentimentos (AS) pode ser uma boa opção para ajudar a identificar de diversos tipos de emoções, entre elas os comportamentos tóxicos.

Uma emoção é um conjunto de respostas químicas e neurais baseadas nas memórias emocionais, e surgem quando o cérebro recebe um estímulo externo. O sentimento, por sua vez, é uma resposta à emoção e diz respeito a como a pessoa se sente diante daquela emoção (Movimento Saúde, 2019).

Dentro desse campo de estudo, a Análise de Sentimentos (*Sentiment Analysis)* vem ganhando espaço durante os últimos anos, tendo como principal atividade “identificar o sentimento que os usuários apresentam a respeito de

alguma entidade de interesse.” (RODRIGUES, Calos Augusto S.; VIEIRA, Leonardo Lino; MALAGOLI, Leonardo; TIMMERMANN, Níkolas, 2013).

Análise de Sentimento, segundo Silva, Barbosa Pandolfi e Cazella (2017) pode ser definido como:

> *“A Análise de Sentimento é um campo de estudo importante para a Computação Afetiva e para a compreensão dos processos cognitivos em geral. Dois aspectos embasam essa constatação: a web ter se tornado uma arena pública para difusão de opiniões; e a comunicação, desde a mais tenra idade, ser expressa a partir de múltiplas linguagens.”*

Para categorizar os sentimentos apresentados pelos jogadores durante as conversas em uma partida MOBA, com o intuito de evidenciar o comportamento tóxico dos demais, serão utilizadas técnicas referentes à Ciência de Dados (*Data Science*).

Em um alto nível, a Ciência de Dados é um conjunto de princípios fundamentais que apoiam e orientam a extração de informações e conhecimento dos dados com base em princípios. Possivelmente, o mais próximo conceito relacionado à Ciência de Dados é a Mineração de Dados que trabalha com a extração de conhecimento de dados por meio de tecnologias que incorporem esses princípios (PROVOST; FAWCETT, 2013).

De maneira resumida, em geral, a execução de um protótipo baseado em critérios estabelecidos pela Ciência de Dados pode ser representada nos seguintes passos: (ZHAO, 2018)

1. Identificar um elemento de pesquisa;
2. Obter um *dataframe* e ajustá-lo para elaboração da Análise Exploratória;
3. Executar o EDA (*Exploratory Data Analysis* - Análise Exploratória de Dados);
4. Aplicar as técnicas (Algoritmos);
5. Compartilhar os resultados.

Considerando a Ciência de Dados como fator essencial para esse trabalho, busca-se responder as seguintes questões:

1. Quais os principais tipos de comportamento e sentimentos que ocorrem durante as partidas?
2. Que tipo de diferenças de resultados serão obtidos realizando os testes com algoritmos de Clusterização (*K-Means*) e Modelos de Tópico (LDA – *Latent Dirichlet Allocation*)?
3. É possível gerar resultados satisfatórios o bastante para que possam ser utilizados posteriormente por outros mecanismos que buscam mitigar o comportamento tóxico em jogos?

É relevante estudar esse tema, pois a cada vez mais pessoas entram no mundo dos jogos, fazendo com que seja importante saber como se comportam nesse ambiente virtual, podendo ser visualizado pela empresa dona do jogo e pela comunidade que consume o seu produto, a fim de melhorar o ambiente do jogo, já que muitos jogadores casuais são influenciados e até mesmo atrapalhados pelos jogadores definidos como tóxicos.

Dentro do contexto de MOBAs, os estudos apresentados neste trabalho serão focados principalmente em evidenciar o comportamento tóxico apresentados pelos jogadores. Comportamento tóxico este, referido por Suler (2004) como uma presença constante em jogos online, ocorrendo quando um jogador quebra regras de convivência, agindo de maneira ofensiva.

De acordo com Joaquim Alvino de Mesquita Neto (2019):

> *“Insultos, provocações e culpabilizações são a forma mais clássica de comportamento tóxico, mas outros comportamentos também são considerados ofensivos por jogadores online, como perder uma partida de propósito ou abandonar uma partida repentinamente e como resultado, o humor dos jogadores na partida (principalmente do time do autor do comportamento tóxico) ficam deteriorados negativamente, atrapalhando a experiência de jogo.”*

Para fazer a classificação pretendida, foi utilizado como base os dados de aproximadamente 1600 partidas de DotA 2, nos quais foram aplicadas técnicas de *Machine Learning* (Aprendizado de máquina) para descobrir e classificar os padrões comportamentais mostrados durante tais conversas entre os jogadores.

Logo, diante de todo esse contexto, esse trabalho apresenta como objetivo principal, o uso de técnicas de Clusterização e modelagem de tópicos para identificar padrões comportamentais que são mostrados durante partidas de jogos *online* com base nos chats do jogo DotA *2,* identificando principalmente comportamentos tóxicos. Esse trabalho também busca gerar dados satisfatórios o bastante para serem adotados por algum mecanismo que possa mitigar este comportamento em forma de punições por exemplo.

Em decorrência desse estudo serão explorados também os seguintes objetivos específicos:

- Utilizar e comparar pelo menos dois algoritmos de metodologias diferentes de agrupamentos de dados para identificar diferenças entre as duas formas de classificação;
- Categorizar os sentimentos identificados nas conversas dos jogadores, em especial, os sentimentos que definem um comportamento tóxico;

Para fazer tais comparações e classificações, o trabalho se iniciou com a definição quanto ao tema exato a ser estudado em relação a área de Inteligência Artificial, levando a escolha da *Machine Learning* e da Análise de Sentimentos.

Entre opções como sites, blogs, fóruns entre outros relacionados ao tema de jogos, foi escolhido um *dataframe* de *chats* de mais de 1600 partidas do jogo *DotA2*, estando de acordo com o tema do estudo, pois é possível visualizar tudo o que é “digitado” (exposto) durante as partidas de um dos jogos mais populares do mundo atualmente.

Com o *dataframe* disponível, o próximo passo foi definir os algoritmos que farão o agrupamento de dados para a geração dos resultados. Para isso, foram escolhidos dois algoritmos que têm a forma de funcionamento similar, mas que usam técnicas de trabalho um pouco diferentes. Foi feita uma comparação do método de trabalho de Clusterização (*Clustering*) e do Modelo de Tópico (*Topic Modeling*) com seus representantes os respectivos algoritmos, *K-Means* e *LDA*.

Ao fim da codificação, foram realizados testes para identificar se há Superajuste ou Sobreajuste (*Overfitting*) ou Sub-ajuste (*Underfitting*) e por fim, foi feita uma discussão sobre os resultados obtidos para a validação dos dados, podendo essa parte da metodologia ser repetida, caso seja necessário.

Espera-se que os dados obtidos neste trabalho possam auxiliar na percepção de diferentes sentimentos presentes durante partidas de algum jogo *online*, visando ajudar a obtenção de dados para pesquisas em áreas relacionadas com o tema proposto, facilitando a identificação dos padrões comportamentais dos jogadores.

O restante deste trabalho está organizado como segue. O Capítulo 2 traz alguns conceitos importantes para o entendimento e realização do trabalho. O Capítulo 3 traz a descrição dos principais trabalhos relacionados. O Capítulo 4 demostra toda a metodologia de pesquisa aplicada, ambiente de implementação, e a descrição da solução. O Capítulo 5 mostra os resultados alcançados através das análises realizadas. O Capítulo 6 apresenta as conclusões sobre a pesquisa e dos trabalhos futuros. Por fim, o Apêndice A apresenta os links para visualização da codificação desenvolvida na pesquisa e o Apêndice B apresenta o *dataframe* e o *dataset* utilizados para o estudo proposto neste trabalho.

2. Conceitos teóricos relevantes

Neste capítulo serão apresentados conceitos fundamentais para o entendimento deste trabalho. O gênero de jogo MOBA será apresentado de maneira geral. Será apresentado também o jogo DotA 2**,** jogo do qual foram retirados os *chats* usados como objeto de estudo nesse trabalho.

Adicionalmente, serão apresentados conceitos envolvendo *Machine Learning* e os algoritmos utilizados. Por fim, serão esclarecidas definições sobre a Análise de Sentimentos e a classificação utilizada para o desenvolvimento do trabalho.

2.1. MOBA

MOBA é um estilo de jogo que envolve ação, estratégia e um pouco de RPG, tudo ao mesmo tempo. Um MOBA conta com dois times, cada um contendo 5 jogadores que lutam em um mapa apresentado geralmente de forma simétrica em busca da destruição da base inimiga.

Sua origem se deu na criação de um mapa personalizado para o jogo *Aeon of Strife* por fãs do jogo *StarCraft*. Com o sucesso do modo de jogo criado, o jogo *Warcraft III* também ganhou um mapa customizado em 2002, mapa o qual foi responsável por estabelecer as regras atuais da modalidade (CAETANO, 2019).

Como competição nos esportes eletrônicos, o MOBA é caracterizado como o gênero mais popular. Seus dois principais representantes – *League of Legends* e DotA 2 - estão firmemente consolidados neste meio, apresentando premiações milionárias anualmente (SOUZA, 2020)

O tempo de jogo de um MOBA pode variar bastante dependendo da situação da partida, mas suas durações costumam ser em média por volta de 30 a 45 minutos. O jogo consiste em 3 *lanes* (rotas) e a *jungle* (selva) de cada um dos times e o tempo de jogo se divide entre o *Early, mid e late game* (Início, meio e fim de jogo), com cada etapa visando um objetivo diferente, desde a coleta e acúmulo de recursos iniciais, a lutas por grandes objetivos no mapa buscando invadir a base inimiga para finalizar a partida.

Neste tipo de jogo, onde a estratégia é algo essencial para conquistar objetivos enquanto impede o time inimigo de avançar, a comunicação é algo de extrema importância, seja por *chat* de voz ou por *chat* de texto. Atualmente o meio de comunicação mais utilizado nos MOBAs são os *chats* de texto e os *pings* (Sinalizações dentro de jogo) (NETO, 2019).

2.2. DOTA 2

O DotA 2 é um MOBA desenvolvido pela Empresa **Valve** com base no jogo *Warcraft*, e que teve seu lançamento em 2013 em sua plataforma atual, a *Steam* (DABUL, 2013).

O jogo conta com diversos heróis, cada um com suas peculiaridades, além de itens com os quais o jogador monta sua *build* (conjunto dos itens) durante a partida. Cada escolha de herói juntamente de seus itens pode mudar drasticamente o desempenho do herói, além da estratégia empregada no jogo, fazendo com que estratégias de ataque e defesa tenham mudanças constantes durante a partida.

O mapa de DotA 2, mostrado na Figura 1, é composto de dois lados: Um para a facção *Radiant* e o outro para a facção *Dire*. Para ganhar, os jogadores devem destruir o *Ancient* inimigo, que é a estrutura mais importante do jogo. O mapa é dividido em 3 *lanes*: A *Top Lane* (caminho superior), a *Bottom Lane* ou *Bot Lane* (caminho inferior) e a *Mid Lane* (caminho central). Em cada uma das *lanes* estão posicionadas torres que impedem o avanço a base que elas protegem. Separando ambos os lados do mapa, existe também um rio que é cercado por altos terrenos que bloqueiam a visão dos jogadores por ambos os lados. A *Jungle* do mapa se refere a área com árvores que ficam entre cada uma das 3 *lanes*. Na *jungle* é possível encontrar monstros neutros que são abatidos para poder obter experiência para seu herói e ouro para comprar seus itens.

Figura 1. Mapa do jogo DotA 2.

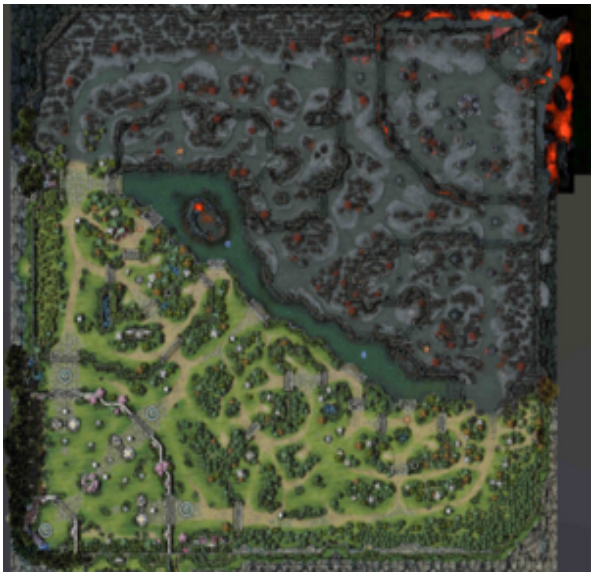

(a) Mapa Completo.

(b) Disposição das *lanes*.

Fonte: (a) DOTA 2 WIKI, 2018; (b) Fonte: DOTA 2, 2014.

De acordo com o site *Esports Earnings* (2020), o DotA 2 ocupa a posição mais alta no ranking dos que mais premiam, chegando a pagar anualmente mais de US$ 231 milhões em competições competitivas. Em 2021 o jogo chegou a registrar mais de 1 milhão de jogadores simultaneamente.

Os jogadores se comunicam no DotA2 a partir de *chat* de texto e voz, ilustrados nas figuras 2 e 3, além de *pings* com avisos pré-definidos. O *chat* de texto é geralmente divido entre um *chat* de visibilidade somente para aliados (membros do seu time) e outro *chat* de visibilidade global (Qualquer um que esteja na partida poderá ler).

Figura 2 . Chat de Pings do jogo Dota 2

Fonte: DOTA 2 WIKI, 2021.

Figura 3. Chat de texto do jogo DotA 2.

Fonte: TU, 2018.

2.3. *Machine Learning*

Machine Learning é um ramo da Inteligência Artificial (IA) e da Ciência da Computação que é concentrada no uso de dados e algoritmos para imitar a forma como os humanos aprendem, melhorando gradativamente sua precisão (IMB, 2020).

Esse processo de aprendizagem começa com observações ou dados como exemplos, experiência direta ou instruções dadas, a fim de procurar padrões nos dados e tomar as melhores decisões com base nos exemplos fornecidos (EXPERT.AI, 2020).

Uma das vertentes importantes da Ciência da Computação, que apresentam elementos de *Machine Learning* é a área de Processamento Natural de Linguagem, que será explicada a seguir.

2.3.1. Processamento de Linguagem Natural

Ainda que o tema demande conhecimento linguístico e técnico intermediário, a definição de Linguagem Natural é bem simples. Trata-se da pura forma como os humanos se comunicam. Os idiomas são um ótimo exemplo de Linguagem Natural (BERTIN, 2020).

Processamento de Linguagem Natural (PLN) é uma vertente da inteligência artificial que ajuda computadores a entender, interpretar e manipular a linguagem humana. O PLN resulta de diversas disciplinas, incluindo Ciência da Computação e Linguística Computacional, que buscam preencher a lacuna entre a comunicação humana e o entendimento dos computadores. (SAS, 2021)

Utilizando técnicas dessa vertente junto a Análise de Sentimentos, serão feitos os procedimentos necessários para classificação das frases presentes no *dataframe* estudado, de forma que possamos identificar o comportamento tóxico apresentado pelos jogadores presentes no *chat*.

Para esse fim, serão utilizados dois algoritmos que fazem parte desta vertente, mas que trabalham com técnicas de classificação diferentes: O LDA que utiliza de Modelos de Tópicos para fazer sua classificação, e o *K-Means* que utiliza a técnica de Clusterização, que serão apresentados a seguir.

2.3.2. *Topic Models: Latent Dirichlet Allocation* (LDA)

Modelagem de Tópicos (*Topic Models)* é o processo de identificações de tópicos em um conjunto de documentos, semelhante ao agrupamento de dados numéricos, que encontra alguns grupos naturais de tópicos mesmo quando não se tem certeza do que está procurando. (KULSHRESTHA, 2019).

O LDA é uma abordagem probabilística não-supervisionada, que descobre os tópicos de um conjunto de documentos, e descreve documentos a partir da probabilidade de eles pertencerem a algum dos tópicos descobertos. Estes tópicos são descritos como uma distribuição de palavras, por exemplo, um tópico A pode ser representado 40% pela palavra_1, 10% pela palavra_2, 8% pela palavra_3, e assim por diante, para todas as palavras no vocabulário (Neto, 2019).

O LDA funciona da seguinte forma:

- O algoritmo percorre cada frase e atribui aleatoriamente a cada palavra da frase, um dos k tópicos (k é definido de antemão).
- Para cada frase, o algoritmo percorre cada palavra e calcula os itens:
    A. A proporção de palavras na frase analisada que são atribuídas a cada um dos tópicos, e então tenta capturar quantas palavras pertencem a cada tópico na frase. Assim, excluindo a palavra atual (que está sendo analisada), se várias palavras daquela frase pertencerem a um tópico *t*, é mais provável que a palavra que está sendo analisada também pertença àquele tópico *t*;
    B. A proporção de frases que foi atribuído o tópico *t* sobre todas as frases que vem desta palavra que foi analisada. Assim, o algoritmo tenta capturar quantas frases estão no tópico *t* por causa desta palavra

O algoritmo LDA representa as frases como uma mistura de tópicos. Da mesma forma, um tópico é uma mistura de palavras. Se uma palavra *w* tem alta probabilidade de estar em um tópico *t*, todos os documentos com *w* também estarão mais fortemente associados a *t*. Da mesma forma, se a *w* tem uma baixa probabilidade de estar em *t*, as frases que contêm *w*, terão uma probabilidade muito baixa de estar em *t*, porque o resto das palavras na frase pertencerão a algum outro tópico e, portanto, a frase terá uma maior probabilidade para esse outro tópico. Portanto, mesmo que *w* seja adicionado a *t*, não trará muitos desses documentos a *t*. Ao final, é atualizada a probabilidade da palavra analisada pertencer ao tópico *t* (KULSHRESTHA, 2019).

2.3.3. *K-Means Clustering*

A Clusterização é uma das técnicas de Análise de Dados mais comumente usadas para obter uma intuição sobre a estrutura dos dados. Esta técnica pode ser definida como a tarefa de identificar subgrupos nos dados de

forma que os pontos de dados no mesmo subgrupo (*cluster*) sejam muito semelhantes, enquanto os pontos de dados em diferentes *clusters* são muito diferentes. (DABBURA, 2018)

Dentre os algoritmos de Clusterização mais utilizados está o *K-Means.* O algoritmo *K-Means* é um algoritmo de aprendizagem não-supervisionado e interativo que tenta particionar os dados em subgrupos distintos, onde cada um dos pontos pertence a somente um *cluster*.

Durante este processo, o algoritmo tenta manter os pontos que fazem parte de um mesmo *cluster* o mais perto possível, e os pontos centrais de cada *cluster* (Os centroides) o mais distante um do outro possível.

O *K-Means* recebe como entrada a quantidade de agrupamentos que ele deve encontrar, a métrica a ser utilizada para estabelecer as distâncias entre os dados, e bem como os dados em forma vetorial. Após isso o algoritmo seleciona os seus centroides de acordo com a quantidade de *clusters* selecionados. Esta escolha é feita de forma aleatória dentre os dados presentes no *dataframe.*

Com os centroides selecionados, o algoritmo atribui cada um dos pontos ao centroide mais próximo, e quando os *clusters* estiverem devidamente formados, é recalculado os centroides dos *clusters*. Este processo de agrupar os pontos aos seus centroides mais próximos e recalcular os centroides é feito diversas vezes. Para esse trabalho foi definida uma interação com o número máximo de 100 repetições, ou seja, o algoritmo repetirá esse loop 100 vezes e retornará os pontos de acordo com o centroide mais próximo a eles.

A seguir serão apresentadas as métricas de avaliação, que tem como objetivo efetivar a qualidade do modelo proposto assim como seu percentual de acerto para que seja possível visualizar se os algoritmos conseguiram atender os requisitos propostos.

2.3.4. Métricas de Avaliação

Para medirmos o desempenho e precisão dos modelos desenvolvidos aplicando técnicas de *Machine Learning,* é necessário usar uma ou mais

métricas de avaliação para ajudar a fazer a avaliação da capacidade de acerto dos modelos.

Neste trabalho são utilizadas duas métricas de avaliação: a Acurácia (*Accuracy* / Taxa de Acerto) e a Matriz de Confusão. A acurácia é uma métrica bem simples, já que indica basicamente a taxa percentual de acerto dos algoritmos.

Em problemas de classificação binária é utilizada uma matriz de tabulação cruzada (Matriz de Confusão) dos resultados preditos com as classes originais observadas. Essa matriz busca entender a relação entre acertos e erro que o modelo apresenta (NOGARE, 2020). A Matriz de Confusão é uma matriz 2x2 que representa categorias de classificação a partir de 4 notações, que são ilustradas na Tabela 1:

Tabela 1. Tabela da Matriz de Confusão

		Valor Predito	
		Sim	**Não**
Real	**Sim**	Verdadeiro Positivo (TP)	Falso Negativo (FN)
	Não	Falso Positivo (FP)	Verdadeiro Negativo (TN)

Fonte: NOGARE, 2020.

- VP = Verdadeiro positivo – Classificar como ‘Não-tóxico’ e realmente for ‘Não-tóxico’;
- FN = Falso Negativo – Classificar como ‘Não-tóxico’ quando, na verdade for ‘Tóxico’;
- FP = Falso Positivo – Classificar como ‘Tóxico’ quando, na verdade for ‘Não-Tóxico’;
- VN = Verdadeiro Negativo – Classificar como ‘Tóxico’, e realmente for ‘Tóxico’;

2.4. Análise de sentimentos

Para enfatizar o que já foi supramencionando, o conceito de Análise de Sentimento (também conhecida como Mineração de Opinião) é o processo de

extrair informações selecionadas de um texto e determinar a atitude que o escritor está tentando expressar através da linguagem (THOMPSON, 2017), podendo ser utilizada por exemplo para saber se um produto de uma empresa está sendo bem recebido pelos usuários.

Nesse trabalho será aplicada uma das formas mais simples de análise de sentimentos, que é a baseada em polaridades, ou seja, verificar se os sentimentos nas frases são positivos (não-tóxicos) ou negativos (tóxicos). Essa medida pode ser tanto um número real, como um valor discreto. Neto (2019).

Para realizar a classificação, seria necessário um *dataset* com frases classificadas com tais emoções relacionadas ao ambiente de jogos *online*. Porém, dadas as dificuldades para atingir tais requisitos, o *dataset* selecionado para o trabalho foi classificado de forma manual para atender a demanda da pesquisa.

No próximo capítulo, serão apresentados quatro trabalhos que exploram o tema de comportamento tóxico identificados em ambientes virtuais e em jogos do tipo MOBA, bem como, apresenta um trabalho que utiliza técnica de *Machine Learnig* para identificação e classificação de sentimentos durante tais partidas.

3. Trabalhos relacionados

Neste capítulo serão abordados os trabalhos que tem como base de estudo o comportamento tóxico em ambientes online e suas diferentes classificações, assim como será mostrado as causas e fins deste tipo de comportamento.

As principais bases de pesquisas utilizadas foram a *Mary Ann Liebert*. *Inc*., *Google Scholar* (Para pesquisa de Artigos e teses) e *Kaggle*, *Reddit* (Para pesquisa de *dataframes*).

3.1. Comportamento tóxico

Dentre os diversos tipos de locais em que as pessoas apresentam algum tipo diferente de comportamento, em seu artigo, John Suler (2004) procura

mostrar como as pessoas se comportam em redes *online*, onde suas identidades são inicialmente anônimas e como essas pessoas a partir desta anonimidade se comportam.

Mesmo que não exista um termo fixo para definir o comportamento tóxico, em seu trabalho, Suler (2004) pesquisa como o comportamento vindo de um anonimato pode se tornar tóxico, chamado por ele de **desinibição tóxica**, onde é observado uma linguagem rude, críticas severas, raiva, discursos de ódio e até mesmo ameaças. Este comportamento age em contrapartida à **desinibição benigna** que representa comportamentos onde as pessoas compartilham de emoções, medos e até mesmo podem se desviar de seu objetivo para ajudar os outros.

Suler (2004) em seu trabalho também pesquisa, em elementos do ciberespaço, causas e efeitos que podem levar a essa desinibição. Além disso, mostra alguns fatores como, anonimato, invisibilidade e falta de autoridades em meios *online*, que geram o efeito dessa desinibição quando interagem entre si.

Outros trabalhos são discutidos conforme as três categorias em que a literatura pré-existente costuma entender o comportamento tóxico em ambientes *online* (FRAGOSO, 2015).

Estes comportamentos em jogos *online* são o ***Spam***, que consiste em usar em quantidades abusivas recursos de comunicação dentro do jogo (como por exemplo: *Pings* e *chats*). **“Trollagem”**, que tem como objetivo provocar um ou mais participantes de um ambiente *online* com a intenção de incitar discordâncias e confrontos através de comportamentos impertinentes, inferiorização ou ridicularização; e ***Griefing***, que nas interações *online* designam jogadores (e suas ações) que perturbam os demais, tornando desagradável, dolorosa ou até traumática a experiência de jogo. (FRAGOSO, 2015. KURTZ, 2016).

Fragoso (2015) busca em seu trabalho, estudar os comportamentos na comunidade brasileira, denominado por ela como “HUEs”, através das categorias de *troll*, *spam* e *griefing*. Conforme o avanço da pesquisa foi mostrado que os brasileiros são “malvistos” em diversas partes da internet, onde se destacam por seu comportamento único que diferente de outras comunidades, onde parecem refinar cada vez mais seus métodos de comportamento tóxico onde afirmam segundo a autora: “Nada na internet é tão

sério que não possa virar motivo de riso e nada é mais risível do que as pessoas que pensam o contrário".

Kurtz (2016) realizou uma pesquisa em que analisa seis vídeos de partidas de DotA 2 sob a ótica do *griefing*. Nos vídeos analisados, em todos há comportamentos onde é possível identificar alguma das três categorias, ou seja, em todos os casos, houve algum tipo de comportamento que atrapalhou de alguma forma a experiência alheia no jogo.

Tais comportamentos foram vistos por Kurtz (2016) pela visão do software, visando a sua importância para detecção de atos como este. Após as análises, a autora pontua também a necessidade de interação humana nas análises destes dados para análises mais completas e precisas, já que ocorrem casos onde são enviadas provas de comportamento tóxico para análise e o software sozinho não consegue identificar tal comportamento.

Em seu trabalho, Fernandez (2017) busca compreender psicologicamente estes fenômenos com o objetivo de aumentar o conhecimento científico sobre o assunto dentro dos jogos *online*, já que os jogos atualmente ocupam uma boa parte da vida de diversas pessoas (FERNANDEZ, 2017).

Fernandez (2017) também mostra que o comportamento tóxico é recorrente nos jogos de gênero MOBA e que este tipo de comportamento cresce cada vez mais, seja pelo anonimato ou pelos fatores associados à desinibição *online*, onde jogadores apresentam cada vez mais comportamentos agressivos e desrespeitosos nos jogos *online*.

Esse estudo tem como base, discussões realizadas a partir de pesquisas em cima das narrativas da literatura sobre o tema de desinibição tóxica que está presente nos meios *online* atualmente, e que, são encontradas abundantemente em jogos *online,* buscando responder o que são e o que ocasiona estes comportamentos.

Os trabalhos estudados buscam mostrar as formas de toxidade apresentadas no mundo *online* e principalmente nos jogos desde mundo virtual, mostrando as possíveis classificações para as emoções presentes no ambiente tóxico e fora dele. A partir desses estudos, os *chats* serão analisados e classificados de maneira que os algoritmos propostos possam obter um percentual satisfatório de precisão na classificação proposta.

3.2. *Machine Learning* para identificação do Comportamento tóxico em jogos MOBA

Neto (2019) em seu trabalho, busca caracterizar e prever comportamentos considerados tóxicos usando como base o *chat* do jogo *League of Legends* (LoL), onde a partir da extração de tópicos de texto de sua base de dados, ele compara os vocabulários utilizados pelos jogadores tóxicos e não-tóxicos.

Ele busca através destas *features,* descobrir padrões utilizados por jogadores, e compreender o que ocorre em suas partidas para que medidas que visam diminuir este tipo de comportamento possam ser implementadas por desenvolvedores e gerentes de comunidades de jogos.

Na Tabela 2, estes padrões são encontrados em forma de tópicos de conversação entre os jogadores, que foram divididos entre aliados e inimigos. Estes tópicos variaram entre táticas, educação, bate-papo, reclamações, discussões, insultos e provocações, mostrando a distribuição dos tópicos de acordo com cada tipo de jogador, onde cada entrada indica a taxa de uso de um tópico para cada tipo de grupo. Vemos por exemplo que a soma total de tópicos negativos no estudo realizado por Neto (2019) foi de 43%, onde entre tópico, 19% foram e reclamações e 13% de discussões realizadas durante as partidas.

Foi observado também, as diferenças apresentadas no desempenho dos jogadores com e sem a prevalência de alguns dos tópicos. Na Tabela 3 é mostrado que o comportamento tóxico apresentado dentro do jogo afeta a performance geral da equipe do jogador que apresenta tal comportamento.

Tabela 2. Distribuição dos tópicos nos grupos

Tópicos	Todos	Inimigo	Não Cont.	Inimigo Cont.	Aliado	Ofensor
Tópicos Positivos	57%	81%	86%	73%	55%	35%
Rel. a Táticas	44%	64%	66%	55%	44%	25%
Táticas	21%	24%	26%	22%	22%	16%
Táticas/Educação	24%	40%	44%	33%	22%	9%
Rel. a Humor	36%	57%	58%	51%	33%	19%
Bate-papo	13%	17%	17%	18%	11%	10%
Tópicos Negativos	43%	18%	14%	27%	45%	65%
Reclamações	19%	6%	6%	8%	20%	30%
Discussões	13%	7%	4%	13%	16%	15%
Insultos	7%	3%	2%	3%	6%	13%
Provocações	4%	2%	1%	3%	3%	7%

Fonte: NETO, 2019.

Tabela 3. Comparação das performances médias de grupos com/sem a prevalência de um tópico.

Tópicos	Todos	Não Cont.	Inimigo Cont.	Aliado	Ofensor
Tópicos Positivos	0,104 / 0,081	0,122 / 0,109	0,113 / 0,093	0,090 / 0,077	0.089 / 0,078
Rel. a Táticas	0,103 / 0,087	0,122 / 0,116	0,113 / 0,102	0,089 / 0,081	0,088 / 0,080
Rel. a Humor	0,107 / 0,087	0,124 / 0,114	0,114 / 0,101	0,093 / 0,080	0,089 / 0,080
Tópicos Negativos	0,081 / 0,104	0,109 / 0,122	0,093 / 0,113	0,077 / 0,090	0,078 / 0,089
Reclamações	0,077 / 0,097	0,104 / 0,121	0,087 / 0,109	0,073 / 0,086	0,076 / 0,084
Discussões	0,082 / 0,095	0,113 / 0,120	0,097 / 0,109	0,078 / 0,085	0,077 / 0,082
Insultos	0,084 / 0,095	0,108 / 0,121	0,093 / 0,108	0,080 / 0,085	0,076 / 0,084
Provocações	0,091 / 0,094	0,118 / 0,120	0,097 / 0,108	0,092 / 0,084	0,084 / 0,081

Fonte: NETO, 2019

A Tabela 3 destaca, para cada tópico e tipo de grupo de jogadores, o desempenho médio considerando todos os grupos onde aquele tópico é prevalente e o desempenho médio nos outros grupos (ou seja, grupos onde outros tópicos são prevalentes). O formato de cada célula representa “desempenho médio do tópico” / “desempenho médio dos outros tópicos”. Por exemplo, a primeira célula da tabela permite comparar o desempenho médio de todos os grupos (Todos) relacionados a um tópico positivo (0,104) com o desempenho médio de todos os outros grupos (0,081), que neste caso são os relacionados a um tópico negativo (NETO, 2019).

Em uma análise mais profunda, Neto (2019) busca desenvolver técnicas mais eficientes no combate ao comportamento tóxico observando o comportamento geral dos jogadores, de forma que os jogadores não-tóxicos não sejam prejudicados.

Finalmente Neto (2019), em suas análises dos padrões encontrados nas conversas dos jogadores, demostra como esse comportamento tóxico afeta cada uma das equipes e como mostra a Figura 4, investiga também quando cada comportamento é mais predominante, ou seja, é apresentado o índice de presença de cada tópico em cada uma das emoções estudadas por ele. Por exemplo, é possível observar que o tópico de Discussões tende a aparecer em maior frequência em emoções positivas, como alegria e confiança. Segundo Neto (2019), isso se deve ao fato de que este tópico busca conter o comportamento tóxico, possivelmente buscando resolver algum tipo de conflito.

Figura 4. Comparação entre os tópicos mais e menos presentes para cada emoção

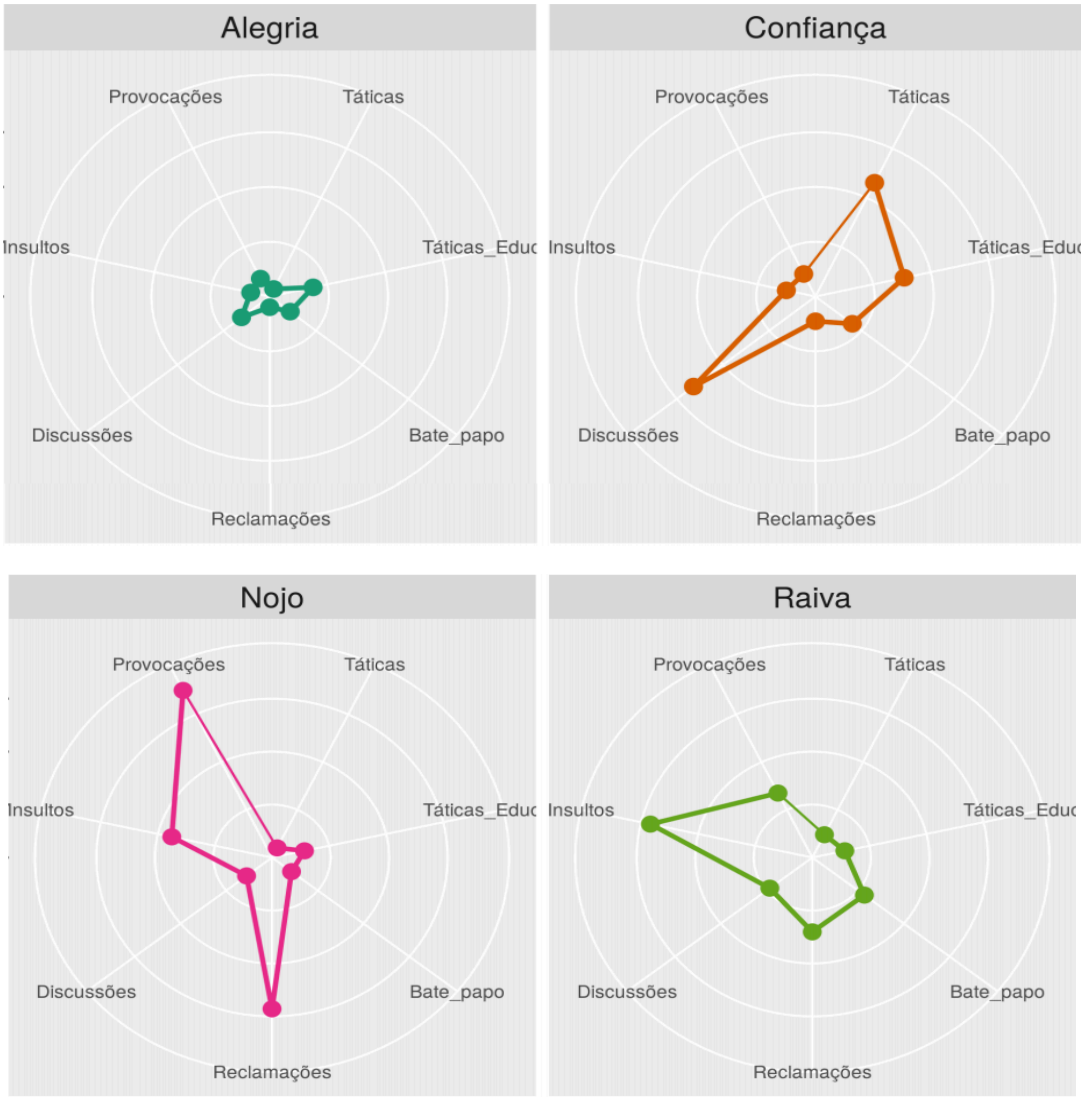

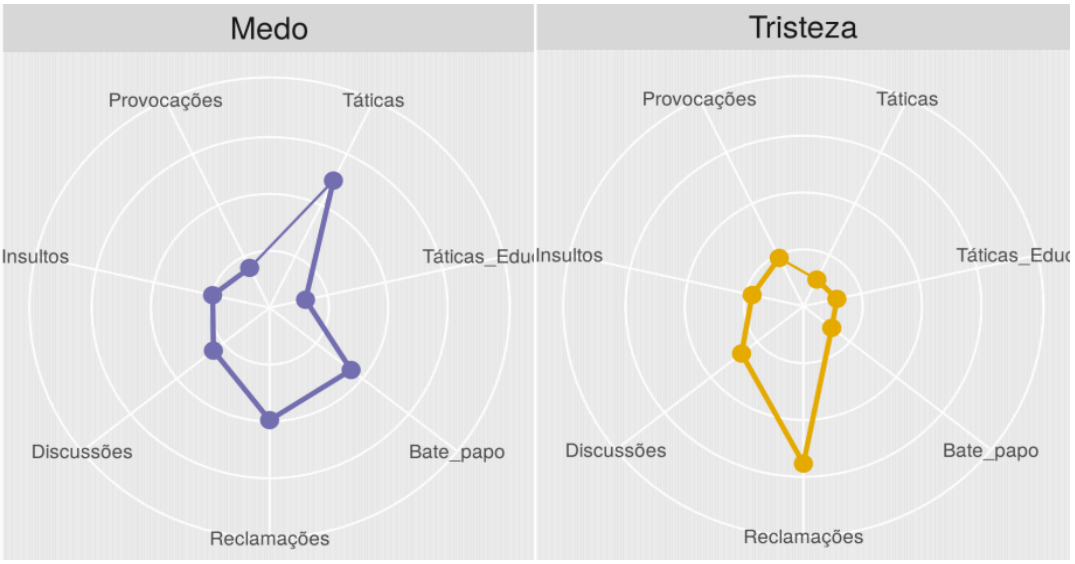

Fonte: NETO 2019.

Por fim, Neto (2019) demonstra que há dois principais patamares nos valores de emoções dos tópicos: os positivos apareceram com menos emoções e os negativos, que apresentaram mais emoções. Cada sentimento foi caracterizado a um destes tópicos de acordo com a maneira que cada um se associa.

4. Metodologia de estudo

Esse capítulo descreve todo o desenvolvimento do trabalho. São apresentados o ambiente de desenvolvimento, os algoritmos implementados, e como foi desenvolvida toda a solução do estudo feito.

4.1. *Python*

Python é uma linguagem de programação de alto nível bastante versátil, suportando a Programação Orientada a Objetos e a estruturada. Criada em 1991, o *Python* atualmente possui código aberto que é gerenciado pela *Python Software Foundation.*

Python é uma linguagem poderosa e simples. A linguagem contém estruturas de dados de alto nível e bastante eficientes, além de uma abordagem simples, porém eficaz para a Programação Orientada a Objetos.

Algumas de suas principais características está em sua leitura mais simples e a necessidade de poucas linhas de código quando comparada a outras linguagens.

Dentro do universo da Ciência de Dados, o *Python* é a linguagem de programação que mais cresce no mercado. De acordo com a pesquisa KDniggets 2016 sobre as principais ferramentas de análise em Ciência de Dados, a linguagem R ainda estava no topo da lista de ferramentas, porém a participação do *Python* no mercado aumentou em 51%, demostrando sua influência neste campo de estudo.

Outra característica que faz o *Python* ser um diferencial na área de ciência de dados são suas bibliotecas. A linguagem fornece diversas bibliotecas e estruturas para a análise de dados. Neste trabalho as principais bibliotecas utilizadas foram: *Pandas*, *NumPy*, *Matplotlib*. *Scikit-Learn*, *pyLDAvis*, *Seaborn* e NLTK.

4.1.1. *Pandas*

Pandas é uma biblioteca que é utilizada como uma ferramenta para ler e gravar dados entre estruturas de dados na memória em diferentes formatos como: Arquivos CSV, arquivos de texto, Microsoft Excel, banco de dados SQL e o formato rápido HDF5;

A biblioteca atualmente possui um alinhamento inteligente de dados e um manuseio integrado de dados perdidos, uma remodelagem de conjunto de dados, manuseio de *Data Frames* etc.

A biblioteca *Pandas* foi utilizada no trabalho para a manipulação geral do *dataframe* e do *dataset* utilizados para o estudo. Essa manipulação dos dados contou principalmente com a leitura dos arquivos CSV, alinhamento dos dados, tratamento de dados ausentes, inserção e retirada de colunas, junção de conjunto de dados e filtro de dados.

4.1.2. *NumPy* (*Numerical Python*)

O *NumPy* é um projeto de código aberto que visa habilitar a computação numérica na linguagem de programação *Python*. A biblioteca foi criada em 2005, com base no trabalho anterior das bibliotecas *Numeric* e *Numarray*.

NumPy é um pacote fundamental para a computação científica em *Python*. É uma biblioteca padrão quando se trabalha com dados numéricos em *Python* e esta sempre presente em estudos científicos com *Python*. A biblioteca é usada extensivamente junto com a *Pandas*, *SciPy*, *matplotlab*, *Scikit-Learn*, *Scikit-image* e com a maioria dos outros pacotes de ciência de dados em *Python*.

A biblioteca fornece um objeto matriz multidimensional e estruturas de matriz de dados. Ela fornece um ndarray, um objeto de array n-dimensional homogêneo, com métodos para operar com eficiência nele.

No trabalho a biblioteca foi utilizada principalmente para apresentação de gráficos, com funções para cálculos de contagem em *array*, juntamente da biblioteca *Matplotlib* que será apresentada a seguir.

4.1.3. *Matplotlib*

A biblioteca *Matplotlib* é uma abrangente biblioteca para a criação de formas de visualizações estáticas, animadas e interativas em *Python*.

A biblioteca produz gráficos e figuras com qualidade e com uma grande variedade de formas em várias plataformas.

Utilizando o *pyplot*, o *Matplotlib* traz uma coleção de funções que o faz funcionar como o MATLAB. Cada função *pyplot* faz alguma alteração diferente em uma figura. Por exemplo: Criar uma figura, cria uma área de plotagem em uma figura, decora o gráfico com rótulos etc.

Junto aos resultados obtidos pelo *NumPy*, o *Matplotlib* também foi utilizado para a apresentação de gráficos no trabalho, além de uma visualização geral dos dados.

4.1.4. *Scikit-Learn* (sk-learn)

O sk-learn é uma biblioteca de *machine learning* de código aberto e que dispõe de ferramentas para análise preditiva de dados, trabalhando juntamente com as bibliotecas numéricas e cientificas do *Python*.

A sua principal aplicação é a criação de modelos de aprendizagem de máquina, sendo organizado em vários algoritmos de diversas finalidades, como por exemplo: pré-processamento, classificação, regressão, clusterização, agrupamento etc.

Durante o trabalho a biblioteca foi utilizada para a criação dos modelos do LDA e *K-Means*, além da classificação dos dados dos modelos.

4.1.5. *pyLDAvis*

O *pyLDAvis* é uma biblioteca do *Python* que é usada para visualização de modelos de tópicos interativos. O *pyLDAvis* foi projetado para ajudar os usuários a interpretar os tópicos em um modelo de tópico que foi ajustado a um corpus de dados de texto. Esta biblioteca extrai informações de um modelo de tópicos LDA ajustado para informar uma visualização interativa.

Como as versões mais novas do *pyLDAvis* não funcionam bem no ambiente do *Google Colab*, foi utilizada a versão 2.1.2 neste trabalho para fins de reprodução dos gráficos.

Usado para visualização dos dados apresentados pelo modelo LDA, o *pyLDAvis* apresentou de forma dinâmica os resultados de cada um dos tópicos classificados pelo modelo.

4.1.6. *Seaborn*

Seaborn é outra biblioteca para visualizações de dados no *Python*. Essa, no entanto é baseada no *Matplotlib* e fornece uma interface para gráficos estatísticos, que consegue trazer de forma clara os resultados dos algoritmos estudados.

Assim como a biblioteca *Matplotlib*, o *Seaborn* foi utilizado para a apresentação de gráficos de amostra dos resultados obtidos com os cálculos realizados pelo *NumPy*.

4.1.7. NLTK

O NLTK (*Natural Language Toolkit*) *é* um conjunto de ferramentas para construção de programas em *Python* para trabalhar com dados de linguagem humana. Ele fornece interfaces fáceis de usar, recursos lexicais além de um pacote de bibliotecas de processamento de texto para classificação, tokenização, lematização, marcação, análise e raciocínio semântico. Foi usada no trabalho para a criação dos modelos de *Machine Learning* para a classificação e avaliação dos algoritmos implementados.

Toda implementação do trabalho será realizada no *Google Colaboratory*, também conhecido como *Google Colab*. No *Colab* foi possível criar notebooks para a implementação do trabalho sem nenhuma configuração anterior necessária, com acesso gratuito a GPUs dos servidores Google além de garantir um fácil compartilhamento do documento, podendo ser acessado facilmente de qualquer máquina.

Nos notebooks do *Colab* é possível combinar textos e código em um só lugar, podendo ser feita a inserção de imagens e HTML por exemplo, o que é um diferencial para o trabalho por manter todo o código organizado e com anotações e conceitos entre as sessões de código. Estes notebooks são armazenados em sua conta do Google Drive (nuvem), podendo ser compartilhados e acessados a qualquer momento.

O *Colab* por utilizar como linguagem de programação o *Python*, se tornando uma API onde é possível utilizar todas as suas bibliotecas para a análise de dados. Para realizar estas análises, é possível fazer a importação de dados para o notebook e executar todo o projeto na nuvem, utilizando o hardware do Google independente da máquina que esteja utilizando.

Antes de implementar os algoritmos LDA e *K-Means*, é necessário esclarecer como ocorre o processo de identificação de um comportamento tóxico.

4.2. Identificação de comportamento tóxico

Foi citado inicialmente que um dos principais meios de comunicação em jogos *online* são os *chats* de texto dentro do jogo. Muitas vezes, a maneira como os jogadores estão se sentindo e seus pensamentos são expressos pela ferramenta. Em trabalhos relacionados (NETO, 2019; FRAGOSO, 2015; KURTZ, 2016) mostram que tal meio de comunicação tem alto valor quando se analisa o comportamento dos jogadores no jogo.

A toxidade na comunidade do jogo DotA 2 não é um tópico novo. É um problema que não é exclusivo do jogo, mas ele ainda conseguiu ganhar uma certa reputação por ele (ESTNN, 2021). Para identificação dos comportamentos tóxicos nestes *chats*, é necessário identificar antes o que seria caracterizado como comportamento tóxico e não-tóxico dentro do jogo para assim, **conseguir separar bem os dois tipos de comportamentos e tentar identificá-los.**

Para conseguir chegar nos resultados desejados, algumas barreiras foram encontradas, começando pelo próprio tipo de texto. As conversas de jogadores em MOBAs são cercadas por gírias, códigos, abreviações (Aggro, AoE, Backdoor, BD, Mid, Bot, CD, CDR etc.) e nomes referentes a coisas do próprio jogo (como nome de campeões e itens por exemplo), o que acaba por dificultar o processamento dessas frases. Para definição de tais palavras, foi buscado em um fórum feito de jogadores para jogadores, os significados das mais comumente utilizadas nas partidas (DOTA 2, 2013).

Outra dificuldade encontrada ao longo do trabalho foi a falta de um base de emoções voltado para jogos, ou seja, uma base onde abreviações contidas na maioria dos jogos e até mesmo palavras de conteúdo impróprio ou ofensivo são levadas em consideração. Para contornar esta dificuldade, foi selecionada uma parcela com aproximadamente 3000 frases que estavam presentes no *dataframe* estudado, para criar o *dataset* que irá ser utilizado na implementação do classificador que foi utilizado para classificação e avaliação dos modelos selecionados.

O *dataframe* selecionado precisou passar pela fase de pré-processamento de informações que será descrita a seguir.

4.3. Pré-processamento

Antes de iniciar o estudo dos dados, era necessária uma filtragem deles, pois além das gírias e códigos citados anteriormente, os dados contavam com diversos caracteres que não se fazem presentes no alfabeto latino (alfabeto utilizado na Língua Inglesa), o que mostrava a participação de jogadores de diversos países nos servidores do jogo, mas que eram desnecessários no estudo.

Para o processamento dos dados, foi utilizado como base a mesma linha de procedimentos (com algumas alterações) utilizadas por Neto (2019) em seu trabalho. Os passos a seguir descrevem todo o pré-processamento utilizado:

- **Retirada de caracteres que não fazem parte do alfabeto latino:** como tais dados dificultariam o manuseamento de todo *dataframe*, foram retirados no momento do *upload* do *dataframe* para o ambiente de trabalho.
- **Diminuição do documento trabalhado:** devido ao fato do *Colab* ser um ambiente virtual grátis para uso da comunidade, ele apresenta um limite de hardware. Por este limite ser atingido durante o trabalho, o documento "original" (que continha cerca de 1.4 milhões de frases) foi diminuído para cerca de 5% do seu tamanho original.
- **Transformação em *string*:** todo o *chat* do jogo foi colocado em formado *string* para melhor manuseamento dos dados.
- ***Lower case*:** todo o *chat* do jogo foi colocado em *lower case*, ou seja, feita a normalização em letras minúsculas.
- **Retirada de pontuação:** foi retirada praticamente toda a pontuação existente nas conversas utilizando a biblioteca *Python* de expressões regulares.
- ***Stop words*:** foi feita a remoção das *stop words* nas frases presentes no *dataframe* para menor custo de processamento. Foram utilizadas as *stopwords* presentes na biblioteca NLTK.
- ***Stemming*:** esse é um processo de remoção de radicais das palavras, utilizado para melhorar a performance de processamento.

Com o *dataframe* preparado, o próximo passo se refere à separação da amostragem por palavras mais frequentes, processo essencial para a aplicação futuro dos algoritmos.

4.4. Processo de Amostragem de Palavras mais frequentes

A amostragem se deu por meio de duas ferramentas: *Wordcloud* para mostrar de forma não ordenada as palavras e um gráfico de barras mostrando de forma ordenada as 10 palavras mais frequentes.

4.4.1. *Wordcloud*

A *WordCloud* mostra de forma hierárquica as palavras mais frequentes de um texto, ou neste caso, de um conjunto de textos. Sua forma de mostrar as palavras é ilustrando em maior tamanho as palavras que mais aparecem no texto, e ir diminuindo o tamanho da fonte da letra quanto menos a palavra aparecer (Figura 5). As palavras são colocadas de forma sortida na imagem de saída, ou seja, elas não têm uma posição fixa para aparecer. A nuvem de palavras formada no trabalho tem como quantidade máxima de palavras 5000.

Figura 5. Exemplo de WordCloud

Fonte: WORD CLOUD API, s/d.

4.4.2. Gráfico das palavras mais frequentes

Outra forma de mostrar as palavras mais frequentes dentro do *dataframe* foi plotando um gráfico de barras com a ajuda da biblioteca *Matplotlib* (Figura 6). Diferente da *Wordcloud*, o gráfico de barras mostra também a quantidade de vezes que a palavra mostrada apareceu no *dataframe*, plotando de forma mais organizada, clara e em ordem estas palavras, o que ajuda a ter mais noção dos principais assuntos falados durante as partidas.

Figura 6. Exemplo de Gráfico de Barras.

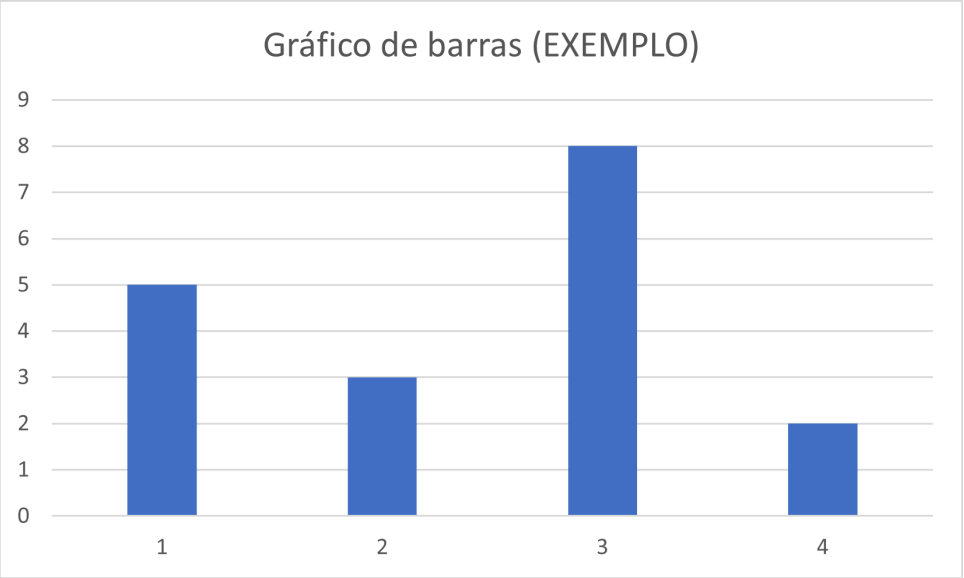

Fonte: Elaborado pelo Autor

Após a preparação do ambiente, do *dataframe* e dos grupos de amostragem das palavras, o próximo passo se refere à aplicação do processo de *Machine Learning* que será descrito a seguir.

4.5. Processo de *Machine Learning* utilizado nesse trabalho

Para o *Machine Learning*, foi necessário trabalhar com um *dataset* diferente do *dataframe* trabalhado anteriormente. Para gerar um classificador para validar as informações que serão geradas pelos algoritmos de agrupamento posteriormente, seria necessário um *dataset* com frases que

fazem parte do universo de vídeo games, pois como dito anteriormente, são diálogos com várias peculiaridades.

Foi neste ponto que surgiu um obstáculo, pois não há *dataset* para este tipo de estudo com fácil acesso e com classificações semelhantes às usadas no desenvolvimento do trabalho. O que dificultou ainda mais a busca por esse *dataset* foi a necessidade de ele ter frases que continham frases relacionadas à *chat* de jogos *online*.

Como solução foram retiradas 3000 frases do *dataframe* de conversas usado originalmente. Esta solução veio após a diminuição drástica do *dataframe* original por limitações da plataforma *Google Colab*, que não suportou o processamento total do *dataframe* durante os agrupamentos feitos pelos algoritmos LDA e pelo *K-Means*.

Neste novo *dataset* gerado, todas as 3000 frases foram classificadas manualmente para gerar da base de emoções que será utilizada para verificar a precisão da classificação por agrupamento que será realizada.

Antes de gerar o classificador foram realizados mais alguns pré-processamentos adicionais necessários para melhor manuseio do *dataset*. Como estas frases já foram retiradas do *dataframe* original após passar pela primeira bateria de pré-processamento, não foi necessário repetir todo o trabalho. Os pré-processamentos adicionais foram:

- **Remoção de colunas:** as colunas de dados irrelevantes para a pesquisa do trabalho foram retiradas do *dataset*.
- ***Notnull*():** foi feito o mapeamento dos dados presentes no *dataset* para detecção de valores não ausentes no *dataset*. Esta função pega um objeto e indica se os valores são válidos.
- ***Stemming*:** utilizando a biblioteca NLTK, foi aplicado o *stemming* nas palavras presentes no *dataset*, isso é, a retirada dos radicais das palavras para conseguir melhorar o processamento do algoritmo (por exemplo: "*liked*", "*likely*" e "*liking*" são reduzidas a "*like*").

Continuando a geração do classificador, foi realizada a separação das frases de suas emoções (tópicos) e a separação das palavras, de forma que estas não fariam mais parte de uma frase completa neste momento. Segue um exemplo:

['space creat', 'topic0'] >>> ['space', 'creat']

Realizada a listagem de todas as palavras presentes, foi feita uma busca pelas frequências das palavras que apareciam no *dataset*. Com a frequência em mãos, foi gerada uma lista de palavras únicas, de forma que cada palavra apareceria somente uma vez nesta lista.

Após ter a lista de palavras únicas, foi elaborada uma função para extrair as palavras de cada uma das frases. Explicando melhor, ao passar uma frase como parâmetro, para as palavras presentes na frase que forem encontradas na base de dados, assim como ilustrado na Figura 7, será retornado um valor *True*, caso contrário, o valor *False*.

Figura 7. Retorno de True para as palavras passadas como referência.

```
caracteristicas_frase = extratorpalavras(['space', 'creat'])
print(caracteristicas_frase)
```

```
{'forc': False, 'space': True, 'creat': True, 'hah': False,
```

Fonte: Elaborado pelo autor

O próximo passo foi a geração de uma base de dados com a aplicação da extração das palavras, juntamente com seus respectivos sentimentos (tópicos) já classificados anteriormente. A geração dessa nova base se deu a partir da aplicação de *features* no método *classify* da biblioteca NLTK.

Para gerar o classificador, foi utilizado o *NaiveBayesClassifier* do NLTK que utilizou como parâmetro a base de dados gerada. Nesse classificador, foram utilizados dois tópicos como resultados. Cada um desses tópicos faz referência a um tipo de comportamento. São eles:

- ***Topic0*:** é marcado por frases NÃO-TÓXICAS, ou seja, que o algoritmo não classifica como uma frase que contém toxidade. Neste tópico, por questão de praticidade, foram incluídas todas as frases com qualquer outro tipo de comportamento que não seja tóxico, seja este um comportamento feliz, triste, “nojento” e até mesmo comportamentos considerados ‘neutros’, que não se encaixam com nenhum tipo ou com vários tipos de comportamento, como por exemplo uma frase que tem como texto somente um “ok”.

- ***Topic1*:** é justamente o contrário do *Topic0*. Nesse tópico, são classificadas as frases com toxidade explicitas. Neste tópico São também reunidos os comportamentos tóxicos a partir de frases com palavras de comportamento indevido, como palavrões, racismo, pensamentos negativistas, exposição de reação excessiva sobre algo que aconteceu no jogo, além de palavras referentes a elementos do próprio contexto do jogo que possam determinar algum comportamento tóxico.

Todas as frases foram classificadas levando em consideração os pesos das palavras presentes nelas. Isso leva em conta, por exemplo, a frequência de vezes que uma palavra aparece em um dos tópicos comparado ao outro. Para se ter noção do peso de algumas das palavras, a Figura 8 mostra o quão grande é a chance de uma palavra ser de um tópico, levando em consideração as identificadas com maiores pesos na base.

Figura 8. Palavras com maiores pesos nas frases da base de aprendizagem.

```
print(classificador.show_most_informative_features(10))
```

```
Most Informative Features
                  report = True           topic1 : topic0 =    165.9 : 1.0
                    noob = True           topic1 : topic0 =     55.3 : 1.0
                    team = True           topic1 : topic0 =     39.9 : 1.0
                    shit = True           topic1 : topic0 =     33.2 : 1.0
                    like = True           topic1 : topic0 =     25.6 : 1.0
                    fuck = True           topic1 : topic0 =     24.6 : 1.0
                      ty = True           topic1 : topic0 =     21.1 : 1.0
                     pls = True           topic1 : topic0 =     18.0 : 1.0
                    bobo = True           topic1 : topic0 =     14.8 : 1.0
                      gg = True           topic0 : topic1 =     13.9 : 1.0
None
```

Fonte: Elaborado pelo autor

Na imagem acima, vemos os pesos das 10 palavras com mais influência no momento de decidir o tópico de uma frase. Como exemplo uma frase tenha a palavra “*report”*, ela tem 165,9 vezes mais chance de ser considerada do tópico1.

A partir deste ponto é realizada a classificação por agrupamento dos dois algoritmos que serão implementados, para **a visualização da diferença**

nos resultados da classificação. Foram utilizados os algoritmos LDA, e o *K-Means*.

Para a criação do modelo LDA, foi necessário separar as informações de texto do *dataframe* presentes nos *chats* de conversa do jogo. Após isso, foi realizado todos os pré-processamentos citados anteriormente, mas ainda mantendo as frases separadas em formato de *dataset* (Foi criado um *dataset* separado para salvar os *chats* retirados do *dataframe* original estudado).

Como próximo passo, foi importado e iniciado o *CountVectorizer* da biblioteca *Sklearn*, que transformou os dados de texto em uma matriz de números e vetores, reduzindo os textos a componentes, pois o LDA necessita de dados numéricos como entrada.

Para gerar o modelo do LDA, foi necessário fornecer a matriz de dados gerada pelo *CountVectorizer*, além do número de tópicos: Tóxico ou Não-Tóxico. Após gerado o modelo LDA, foi feito o ajuste dos dados a partir da função *.fit*.

Infelizmente, a saída do algoritmo não é muito legível, portando uma função foi implementada para ser possível visualizar as palavras que foram agrupadas em cada um dos tópicos gerados a partir do score de similaridade do algoritmo e que são apresentadas na Tabela 4A, como exemplo. Esta função faz uma leitura dos componentes do modelo utilizado para encontrar as palavras semelhantes e busca as palavras correspondentes no *CountVectorizer.*

Tabela 4. Tópicos - LDA

```
Topics found via LDA:

Topic #0:
gg lol ez wp haha ggwp fuck ty nice ok wtf yeah come wow min

Topic #1:
game report mid noob team end just pls dont hahaha fucking xd commend shit guys
```

Fonte: Elaborado pelo autor

Com o modelo treinado, foi realizada uma implementação com o *pyLDAvis* para uma melhor visualização dos tópicos gerados, mostradas nas

figuras 9, 10 e 11, principalmente no que diz respeito a quantidade de palavras totais e presentes em cada um dos tópicos, para assim, ser possível determinar de uma maneira mais clara, as relações entre as palavras de cada tópico.

Para continuar o processamento, foi necessário atribuir um dos tópicos gerados a cada uma das frases presentes no *dataframe*. Para isso, foi implementada uma função que verifica cada frase presente no *dataframe*.

Figura 9. Resultados gerais do agrupamento via LDA.

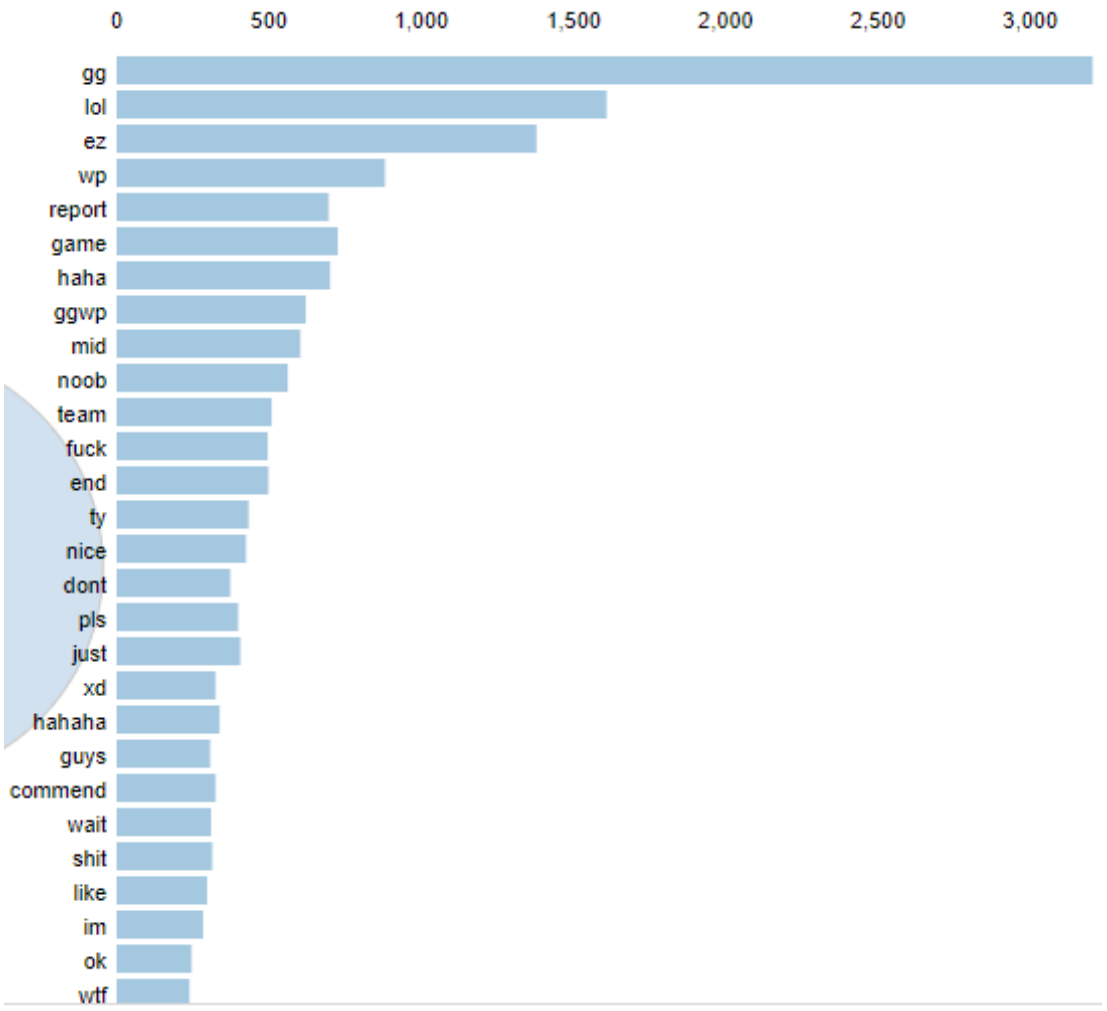

Fonte: Elaborado pelo autor

Através de um processo de contagem simples, foi possível determinar quantas palavras de cada tópico presente na frase, e atribuir o tópico pertinente àquela frase.

Figura 10. Resultados para o tópico 1 - LDA

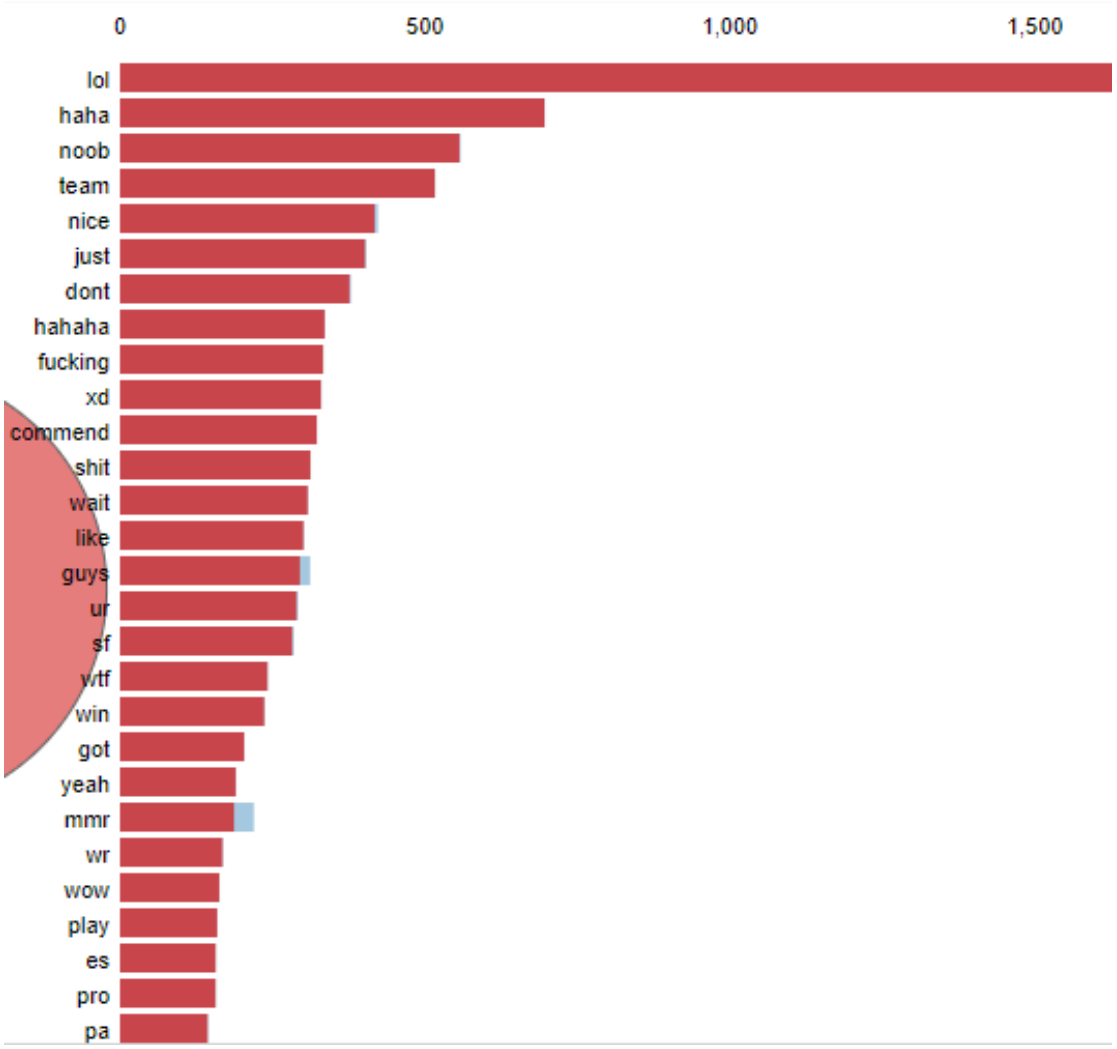

Fonte: Elaborado pelo autor

Figura 11. Resultados para o tópico 2 - LDA

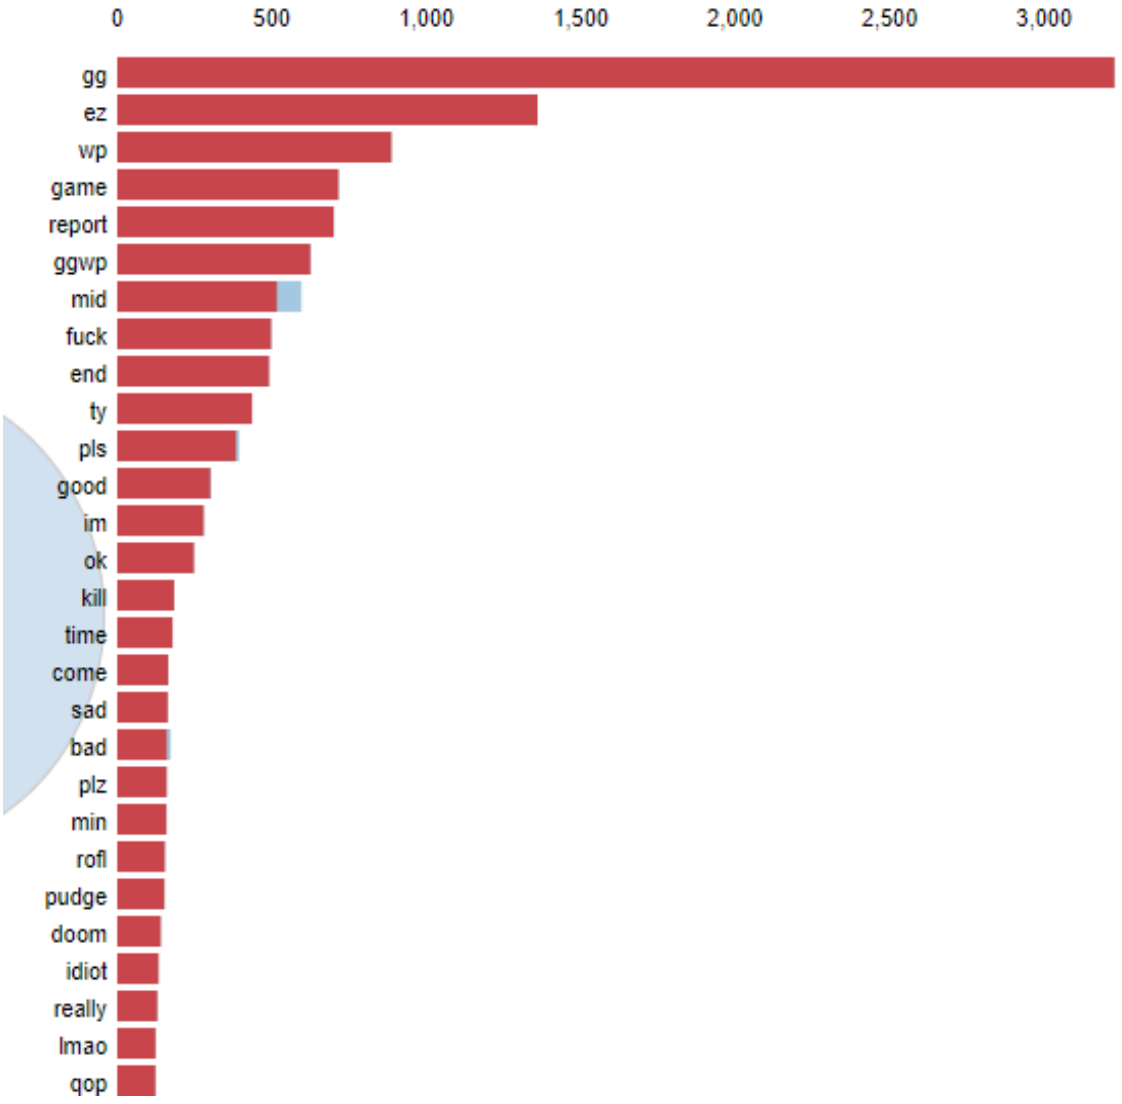

Fonte: Elaborado pelo autor

Para esta função foi criado um dicionário para verificar qual tópico melhor se enquada à frase, para finalmente retornar o resultado. Esses resultados foram guardados em uma lista de tópicos que posteriormente foi adicionada a um *dataset* junto de suas frases correspondentes, para que fosse

possível verificar a avaliação do algoritmo. Observe a Figura 12, com um exemplo.

Figura 12. Dataframe com as frases e seus respectivos tópicos relacionados.

```
# Adicionando a coluna de tópicos ao dataframe
data_list_frame['topics'] = topics_list
```

```
data_list_frame
```

	text	topics
0	force it	topic0
1	space created	topic0
2	hah	topic0
3	ez	topic0
4	mvp ulti	topic0

Fonte: Elaborado pelo autor

Para a criação do modelo do *K-Means*[1], o começo do trabalho foi bem semelhante ao do LDA, já que a separação das frases, mantendo-as em um *dataset* separado a parte, também gerou bons resultados quanto à facilidade de manipulação dos dados.

Com os as frases relacionadas aos seus tópicos, foram importados da biblioteca *Sk-learn* o *K-Means* e o *TfidVectorizer*, que pode converter uma

[1] *Toda a codificação do K-Means foi realizada em um documento diferente, então diversos procedimentos precisaram ser refeitos, porém como toda a parte de bibliotecas e pré-processamentos foram basicamente os mesmos iremos direto pra aplicação do modelo do K-Means.*

coleção de documentos em uma matriz TF-IDF[2] se assemelhando ao *CountVectorizer* em sua função.

Para garantir uma melhor leitura pelo *TfidfVectorizer*, todos os dados da coluna referente às frases no *dataframe* foram transformadas em *Unicode Data*, ou seja, em *Strings*. Esta função faz com que qualquer tipo de símbolo presente nas frases processadas sejam transformadas em formato *Unicode*. Outros pré-processamentos feitos nos dados foram a retirada das *stopwords* do texto e a padronização dos documentos para melhorar seu processamento.

Neste ponto do trabalho, para execução do algoritmo o *K-Means* foi necessário definir a quantidade de *clusters* a serem trabalhados pelo algoritmo. Estes *clusters* nada mais são do que a quantidade de agrupamentos em que os dados serão classificados. Para manter a mesma quantidade de agrupamentos para ambos os algoritmos (LDA usa dois tópicos), foi definida a quantidade de dois *clusters*.

Com a quantidade de *clusters* definida, foi necessário montar o modelo *K-Means* para classificação dos dados. A Figura 13 mostra os hiperparâmetros utilizados na criação do modelo do *K-Means*. Percebe-se que grande parte da configuração padrão foi utilizada:

- o número de *clusters* foi definido anteriormente como 2.
- para o parâmetro *init* foi configurado o modo *k-means++* para inicialização do algoritmo, sendo este o método padrão onde os centróides são gerados utilizando um método de convergência.
- para o *max_inter* foi dado como falor a quantidade de apenas 100 interações, já que testes com maiores quantidade de interações não mostrou diferenças relevantes aos resultados, somente gastando mais tempo de processamento.

Após criação do modelo, foi realizada uma nova padronização, desta vez nos dados do modelo gerado. Esta padronização foi realizada também usando a função *".fit"* que teve como parâmetros, os dados que foram transformados anteriormente na variável *features*.

---

[2] *TF-IDF é uma medida que tem o intuito classificar a importância de uma palavra de um documento em relação a todo o conjunto (SANTOS, 2017).*

Figura 13. Hiperparâmetros K-Means

```
KMeans(algorithm='auto', copy_x=True, init='k-means++', max_iter=100,
       n_clusters=2, n_init=10, n_jobs=None, precompute_distances='auto',
       random_state=None, tol=0.0001, verbose=0)
```

Fonte: Elaborado pelo autor

Aqui foi novamente necessário visualizar as palavras mais presentes em cada um dos *clusters*, assim como foi feito no LDA. Para esse processo, um pequeno código (função) foi implementado após a classificação realizada pelo modelo. Nessa função as palavras mais próximas dos centros de cada *cluster* (centroides) são avaliadas. São retornadas as 30 (trinta) palavras mais próximas de cada centro um dos *clusters,* como mostra o exemplo da Tabela 5. Centroides - K-Means.

Tabela 5. Centroides - K-Means

Centroides:
Cluster 0: gg, , ez, wp, haha, ggwp, report, end, game, , ty , noob, fuck, mid, hahaha, xd, team, nice, pls, commend, wait, wtf, ok, just, don’t, shit, guys, good, sf, fucking, like, rofl
----
Cluster 1: lol, gg, mid, oh, pudge, yeah, sf, wp, np, ok, noob, hook, worth, riki, bitch, lc, need, es, bad, look, bh, solo, lion, vs, comeback, hahah, yea, lag, support, ta
----

Fonte: Elaborado pelo autor

A partir deste ponto, o código voltou a ficar bastante parecido com o utilizado junto ao LDA. Foi criado um dicionário com as palavras mais presentes nos centroides e, após verificar qual *cluster* mais presente naquela frase, atribuiu-se o número do *cluster* àquela frase, com o retorno do resultado. Esses resultados também foram guardados em uma lista de tópicos que foi posteriormente adicionada a um *dataset* junto de suas frases correspondentes.

5. Resultados alcançados

Nesse capítulo serão apresentados os resultados obtidos a partir das pesquisas e testes discutidos no capítulo anterior. Serão apresentadas aqui, as palavras mais relevantes de cada um dos tópicos estudados por ambos os algoritmos utilizados (*K-Means* e LDA), assim como o índice de precisão adquirido de acordo com o classificador implementado. Será apresentada também, para comparação de resultados, a matriz de confusão de ambos os algoritmos que mostrará a quantidade de acertos de cada um dos tópicos de ambos os algoritmos.

5.1. Palavras de maior relevância

Por meio do *WordCloud* (Figura 14) e de gráficos (Figura 15), foi possível observar as palavras com maior quantidade de aparições no *dataset* selecionado, porém para esse trabalho isso não é suficiente. Como os algoritmos selecionados trabalham com o peso de cada palavra para definir o quão importante é aquela palavra para definir o tópico, há o retorno das mais importantes de cada um dos modelos de ambos os algoritmos estudados.

Figura 14. WordCloud do dataframe estudado.

Fonte: Elaborado pelo autor

Para esse estudo, palavras não presentes na Língua Inglesa foram classificadas como palavras “Não-tóxicas”, ou seja, não representam toxidade. Isso se deve ao fato de que são necessários estudos em diversos dialetos para o entendimento de que tipo de sentimento ou opinião está sendo expressa pelo jogador. Foram encontradas frases nos idiomas: Português, Espanhol, Russo, Chinês, Coreano e Japonês.

Figura 15. Palavras mais frequentes do dataframe

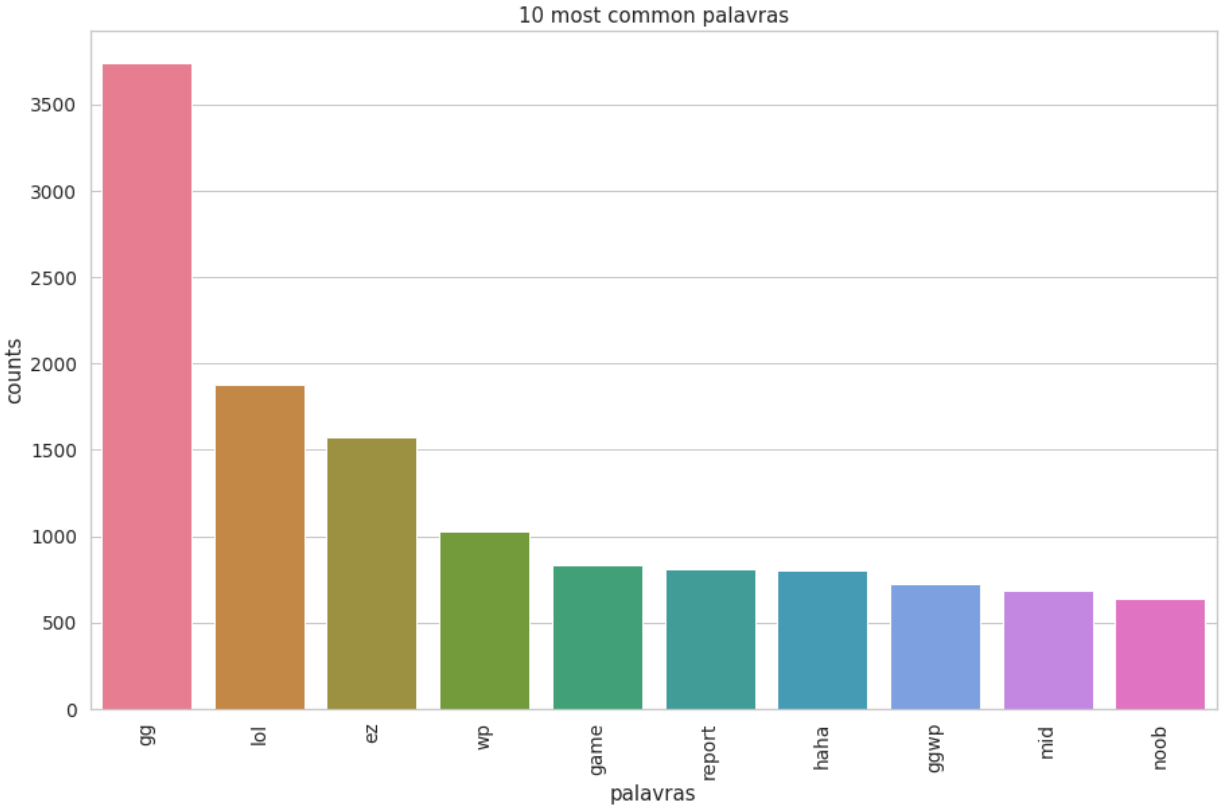

Fonte: Elaborado pelo autor

Como mostrado nas Tabela 6 e Tabela 7, foram consideradas respectivamente, as 15 palavras mais relevantes de cada tópico para o LDA e as 30 palavras mais relevantes para o *K-Means*, e que conseguiram maiores índices de precisão após passar pelo classificador.

Tabela 6. Palavras com maior relevância em cada tópico - LDA

Tópico	Palavras mais relevantes

Tópico #0 (Não-tóxico)	gg, ez, game, mid, haha, nice, fuck, end, don’t, guys, commend, good, wtf, rofl, mmr
Tópico #1 (Tóxico)	lol, wp, report, team, xd, ggwp, ty, pls, noob, just, fucking, shit, sf, like, ur

Fonte: Elaborado pelo autor

Tabela 7. Palavras com maior relevância em cada tópico - K-Means.

Tópico	Palavras mais relevantes
Tópico #0 (Não-tóxico)	gg, ez, wp, team, guys, mid, lol, end, noob, sf, ty, haha, ok, pa, es, pro, plz, carry, wr, time, yeah, win, commend, xd, game, gggggggggggg, im, pudge, hihi, hhehe
Tópico #1 (Tóxico)	lol, ez, haha, ggwp, report, end, game, ty, noob, wp, fuck, mid, hahaha, xd, nice, team, pls, commend, wait, wtf, ok, just, don’t, shit, good, guys, sf, fucking, like, rofl

Fonte: Elaborado pelo autor

Na Tabela 6 pode-se observar uma quantidade menor de palavras em destaque, isso porque o aumento da quantidade de palavras não contribuiu com resultados obtidos. Já como ilustra a Tabela 7, mais palavras foram levadas em peso para o algoritmo, já que o aumento destas palavras levou a uma melhora significativa nos resultados obtidos pelo agrupamento do *K-Means*.

Tais palavras, assim como suas respectivas classificações nas frases, geraram resultados semelhantes na divisão de palavras tóxicas e não-tóxicas como ilustrado nas figuras 16 e 17.

Figura 16. Distribuição dos tópicos no dataframe - LDA

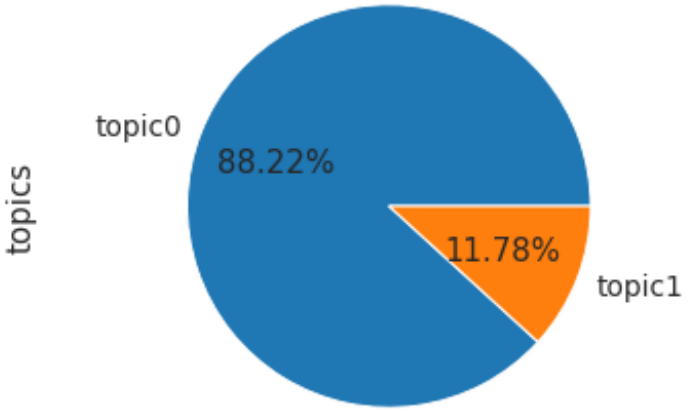

Fonte: Elaborado pelo autor

Figura 17. Distribuição dos tópicos no dataframe - K-Means.

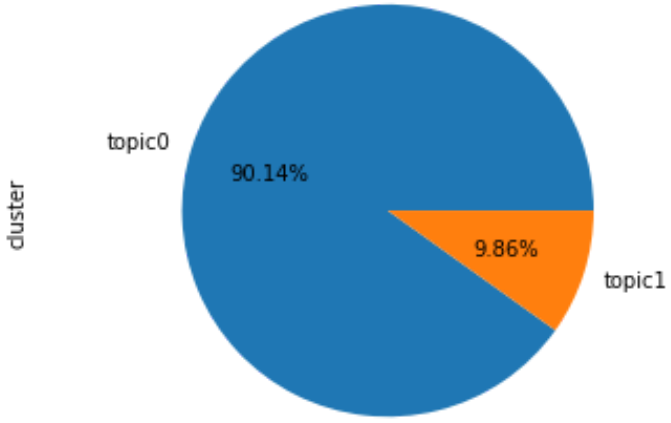

Fonte: Elaborado pelo autor

5.2. Discussão de Resultados

Após se obter os resultados da classificação de cada algoritmo, realizou-se um processo de classificação para determinar seus respectivos índices de acurácia.

Como citado no Capítulo 4, as frases que o classificador desenvolvido no trabalho utilizou para treinamento foram categorizadas manualmente devido à escassez destes tipos de dados voltados para o ambiente de jogos *online*. Após passar pelo classificador, as precisões de ambos os algoritmos foram bem parecidas, ultrapassando os 85% em ambos os casos.

Os melhores resultados obtidos chegaram a 87,69% de precisão pelo algoritmo LDA, por outro lado, o *K-Means* chegou a uma precisão de 86,77%, após diversos testes realizados com mudanças de seus hiperparâmetros.

Dessa maneira observa-se que mesmo com poucas modificações em seus hiperparâmetros e com menor quantidade de palavras relevantes, o algoritmo LDA conseguiu se sobressair ao *K-Means*, que por outro lado, precisou de mais preparações na base de dados e em seus hiperparâmetros. Tais ajustes extras realizados no algoritmo *K-Means*, evidenciam que o algoritmo LDA se mostra mais adequado a esse tipo de estudo considerando, de fato, a metodologia aplicada neste trabalho.

Outra maneira de medir os resultados encontrados pelo classificador LDA e do *K-Means* foi a partida da matriz de confusão.

5.3. Matriz de Confusão

A Matriz de Confusão mostra a quantidade de frases que os algoritmos de agrupamento classificaram em cada um dos tópicos e quantas dessas classificações foram assertivas.

A classificação da Matriz de Confusão para os algoritmos retornou os seguintes resultados:

- Para o LDA, somaram-se 44.205 classificações no tópico de frases não-tóxicas, das quais foram acertadas 41.228 frases. Com isso, a taxa de acerto das frases não-tóxicas chegou a 93%. Já as frases tóxicas classificadas somaram um total de 5.901 frases, das quais foram acertadas 2.710 frases, chegando a uma taxa de acerto de 45%, como pode ser visto na Tabela 8.

Tabela 8. Matriz de Confusão - LDA

	N	*NT = Não-tóxica
	T T	* T = Tóxica
NT	<41228> 2977	
T	3191 <2710>	

Fonte: Elaborado pelo autor

- Para o *K-Means*, somaram-se 45.164 classificações no tópico de frases não-tóxicas, das quais foram acertadas 41.477 frases. Com isso a taxa de acerto das frases não-tóxicas chegou a 91%. Já as frases tóxicas classificadas somaram um total de 4.942 frases, das quais foram acertadas 2.000 frases, chegando a uma taxa de acerto de 40%, como pode ser visto na Tabela 9.

Tabela 9. Matriz de Confusão - K-Means.

	N	T	*NT = Não-tóxica * T = Tóxica
NT	<41477>	3687	
T	2942	<2000>	

Fonte: Elaborado pelo autor

6. Conclusão

Na pesquisa realizada, foi estudado o padrão comportamental tóxico presente na comunidade de jogos *online*. Para isso, foram estudados o comportamento de jogadores a partir de um *dataframe* com aproximadamente 50 mil registros, que apresentava conversas *online* em um dos jogos mais populares mundialmente, o DotA2.

Foi estudado também**,** o tipo de comportamento tóxico e como ele se apresenta em comunidades *online* para serem incluídas na classificação. Foram desenvolvidas as implementações para comparação de resultados de dois algoritmos de agrupamento: o LDA, que faz agrupamento por meio de Modelos de Tópicos, e o *K-Means*, que faz agrupamentos utilizando a técnica de Clusterização.

Confirmou-se, durante a verificação de precisão dos algoritmos utilizados, que a precisão de acerto ficou acima do esperado em ambos os algoritmos, isto porque o estudo de classificação de sentimentos contém várias ferramentas linguísticas que podem não ser tão claras para o computador (a

ironia, por exemplo). Estimava-se que a porcentagem de acertos ficaria entre os 70% e 80%. Isso mostrou que classificação utilizando comportamentos contraditórios (Não-tóxico e tóxico) evidenciou um bom resultado em comparação a testes realizados com mais grupos de classificação, que em alguns testes realizados mostraram resultados de 18% de precisão.

Verificou-se também, que o algoritmo LDA gerou melhores resultados em sua classificação, o que já era esperado do algoritmo, já que o LDA trabalha com classificação, extração de tópicos e agrupamento de textos, enquanto o *K-Means* representa um algoritmo de agrupamentos mais genérico, pois trabalha com textos, como também com valores numéricos.

Em sua precisão geral com 87%, o LDA foi 1,1% mais preciso que o *K-Means*. Além disso, na precisão de ambos os tópicos o LDA se mostrou superior, acertando 2,1% a mais frases Não-tóxicas e 12,5% de frases tóxicas mais frases que o *K-Means*.

Foi visto também que ainda é possível melhorar a classificação de toxidade de ambos os algoritmos, já que a taxa de precisão das frases tóxicas ficou abaixo dos 50%. Para isso, sugere-se uma base de aprendizado mais preparada e específica para o tipo de texto que é visto no ambiente *online*.

Foi observado ainda, que a quantidade de frases tóxicas presentes nas conversas *online*, ficou abaixo do que era esperado. As ferramentas de comunicação dos próprios jogos que, mesmo criadas com o intuito de facilitar o diálogo e organização das equipes, foram apontadas como as mais utilizadas por jogadores tóxicos para projetar provocações, mensagens de ódio ou discriminações, seja por texto ou voz - respectivamente 42% e 40% das vezes (OLIVEIRA, 2020). Neste estudo a taxa de toxidade presente no *dataframe*, ficou com uma média de 10,82% considerando o resultado da classificação de ambos os algoritmos.

Mesmo estando abaixo do esperando, é um fato que a toxidade atinge os jogos *online* e que devem ser desenvolvidas ferramentas para aplicação de punições para este tipo de comportamento. Em grandes jogos existem ferramentas para combate a toxidade em suas comunidades, com punições que levam de um pequeno mute (não poder interagir) por determinado intervalo de tempo à banimentos permanentes no jogo.

Como trabalhos futuros podem ser realizados ainda, estudos mais completos do tema, abrangendo não só dois tópicos contrários um ao outro, mas também tópicos semelhantes, como por exemplo: tristeza, raiva e angústia. Um outro trabalho futuro que pode ser realizado é a implementação de uma ferramenta para aplicação de punições para jogadores que foram detectados utilizando-se de comportamentos tóxicos durante as partidas.

7. BIBLIOGRAFIA

A Biblioteca Scikit-learn – Python para machine learning. Didática Tech – Inteligência Artificial & Data Science. Disponível em: < https://didatica.tech/a-biblioteca-scikit-learn-pyhton-para-machine-learning/ >. Acesso em: 24 de maio. 2021.

BERTIN, Adriano. O que é Processamento de Linguagem Natural? Inbenta, 2020. Disponível em: < https://www.inbenta.com/pt/blog/o-que-e-processamento-de-linguagem-natural/ >. Acesso em: 20 de mar. 2021.

BOLLATI, Eliana. Avançando do problema do racism de DOTA 2. ESTNN, 2021. Disponível em: < https://scikit-learn.org/stable/index.html >. Acesso em: 22 de maio. 2021.

CAETANO, Rafaela. O que são mobas?. ESPN, 2019. Disponível em: < http://www.espn.com.br/infografico/a-gente-explica-e-voce-vira-fa-o-que-sao-os-mobas/ >. Acesso em: 15 de abr. 2021.

DABBURA, Imad. K-Means: Algorithm, Application, Evaluation, Methods, and Drawbacks. Towards, Data Science, 2018. Disponível em: < https://towardsdatascience.com/k-means-clustering-algorithm-applications-evaluation-methods-and-drawbacks-aa03e644b48a>. Acesso em: 22 de maio. 2021.

DABUL, Bernardo. Review DOTA 2. Techtudo, 2013. Disponível em: < https://www.techtudo.com.br/review/dota-2.html >. Acesso em: 23 de abr. 2021.

DOTA 2 Wiki. Gamepedia: Powered by Fandom, 2018. Mapa. Disponível em: < https://dota2.fandom.com/pt/wiki/Mapa >. Acesso em: 19 de mar. 2021.

DOTA 2 Wiki. Gamepedia: Powered by Fandom, 2018. Chat Wheel. Disponível em: < https://dota2.fandom.com/wiki/Chat_Wheel >. Acesso em: 19 de mar. 2021.

DOTA 2. Steam Community, 2014. Dota 2 Lane Information. Disponível em: < https://dota2.fandom.com/pt/wiki/Mapa >. Acesso em: 19 de mar. 2021.

DOTA 2. Steam Community, 2013. The Big Dota 2 Dictionary. Disponível em: < https://steamcommunity.com/sharedfiles/filedetails/?id=172122376 >. Acesso em 20 de nov. 2020.

FERNANDEZ, Amanda. Comportamento Tóxico em Jogos *Multiplayer Online: Uma Revisão Narrativa.* Monografia (Bacharelado) – Universidade Federal de Pelotas, Pelotas. 2017.

GUERRA, Felipe. O que é MOBA? Confira significado e games de sucesso no competitivo. E-SporTV, 2019. Disponível em: <https://sportv.globo.com/site/e-sportv/noticia/o-que-e-moba-confira-significado-e-games-de-sucesso-no-competitivo.ghtml>. Acesso em: 15 de nov, 2020.

Hunter, John et al. Pyplot tutorial. Matplotlib, 2021. Disponível em: < https://matplotlib.org/stable/tutorials/introductory/pyplot.html >. Acesso em: 24 de mar. 2021.

IBM Cloud Education. Machine Learning. IBM, 2020. Disponível em: < https://www.ibm.com/cloud/learn/machine-learning >. Acesso em: 05 de maio. 2021.

IS Python the most popular language for data science? Maruti Techlabs, 2021. Disponível em: < https://marutitech.com/python-data-science/ >. Acesso em: 05 de maio. 2021.

KURTZ, Gabriela. A ética dos computadores e a ética dos *griefers* nos jogos League of Legends e Dota 2. Artigo – Faculdade Federal do Rio Grande do Sul. Porto Alegre, BR–RS, 2016.

LARGHI, Nathália. Brasil é o 13º maior mercado de games do mundo e o maior da América Latina. Valor Investe, 2019. Disponível em: <https://valorinveste.globo.com/objetivo/empreenda-se/noticia/2019/07/30/brasil-e-o-13o-maior-mercado-de-games-do-mundo-e-o-maior-da-america-latina.ghtml>. Acesso em: 16 de nov. 2020.

MABEY, Ben. pyLDAvis. pyLDAvis, 2015. Disponível em: < https://pyldavis.readthedocs.io/en/latest/readme.html >. Acesso em: 2 de abr. 2021.

Murnion, Shane et al.. Machine learning and semantic analysis of in-game chat for cyberbullyng. Computers & Security, v. 36, p. 197-213. Jul. 2018. Disponível em: <https://doi.org/10.1016/j.cose.2018.02.016>. Acesso em: 28 out. 2020.

NETO, J. Uma análise sobre o comportamento tóxico em jogos on-line baseada em tópicos de conversa. Dissertação (Mestrado) – Faculdade Federal do Rio Grande do Sul. Porto Alegre, BR–RS, 2019.

NLTK 3.6.2 documentation. NLTK Project, 2021. Disponível em: < https://towardsdatascience.com/latent-dirichlet-allocation-lda-9d1cd064ffa2 >. Acesso em: 19 de mar. 2021.

New Report from The NPD Group Provides In-Depth View of Brazil's Gaming Population. NPD Group, 2015. Disponível em: <https://www.npd.com/wps/portal/npd/us/news/press-releases/2015/new-report-from-the-npd-group-provides-in-depth-view-of-brazils-gaming-population/>. Acesso em: 13 de nov. 2020.

NOGARE, Diego. Performance de Machine Learning – Matriz de Confusão. Diego Nogare: Inteligência Artificial & Machine Learning, 2020. Disponível em: < http://diegonogare.net/2020/04/performance-de-machine-learning-matriz-de-confusao >. Acesso em: 05 de maio. 2021.

NUMPY: The absolute basics for beginners. NumPy, 2021. Disponível em: < https://numpy.org/doc/stable/user/absolute_beginners.html >. Acesso em: 2 de abr. 2021.

OLIVEIRA, Matheus. Toxidade: O mal de uma geração no esport. MGG, 2020. Disponível em: < https://br.millenium.gg/noticias/4107.html >. Acesso em: 23 de maio. 2021.

O que são os eSports?. CBeS – Confereração Brasileira de eSports. Disponível em: <http://cbesports.com.br/esports/esports-o-que-sao/>. Acesso em: 14 de nov. 2020.

PROCESSAMENTO de Linguagem Natural. SAS, 2021. Disponível em: < https://www.sas.com/pt_br/insights/analytics/processamento-de-linguagem-natural.html >. Acesso em: 09 de maio. 2021.

PROVOST, F; FAWCETT, T. Data Science and its relationship to Big Data and Data-Driven decision making. Big Data. v. 1, n.1, p. 51-59. fev 2013. Disponível em: <http://doi.org/10.1089/big.2013.1508>. Acesso em: 27 out. 2020.

PYTHON. Wikipédia, a enciclopédia livre, 2021. Disponível em: < https://pt.wikipedia.org/wiki/Python >. Acesso em: 18 de mar. 2021.

RODRIGUES, C. et al. Mineração de Opinião/Análise de Sentimentos. Santa Catarina: UFSC, 2013. Disponível em: <http://www.inf.ufsc.br/~luis.alvares/INE5644/MineracaoOpiniao.pdf>. Acesso em 02 de abr. 2019.

SANTOS, Vinicius dos. Term Frequency (TF) e Term Frequency – Inverse Document Frequency (TF-IDF). Computer Science Master, 2017. Disponível em: < https://www.computersciencemaster.com.br/term-frequency-e-term-frequency-inverse-document-frequency/ >. Acesso em: 28 de abr. 2021.

SILVA, Lucas. Análise de sentimentos em contexto: Estudo de caso em blog de empreendedorismo. Monografia (Bacharelado) – Universidade de Brasília – UnB, Brasília, 2013.

Scikit-Learn Developers. Feature extraction. Scikit-Learn, 2007-2020. Disponível em: < https://scikit-learn.org/stable/modules/feature_extraction.html > . Acesso em: 19 mar. 2021.

Scikit-Learn Developers. Naive Bayes. Scikit-Learn, 2007-2020. Disponível em: < https://scikit-learn.org/stable/modules/naive_bayes.html > . Acesso em: 19 mar. 2021.

SOUZA, Amanda. Você já conhece todos os tipos de *E-Sports*? Plataforma *e-SporTI*, 2020. Disponível em: < https://e-sporti.com.br/noticias/2020-11-voce-ja-conhece-todos-os-tipos-de-e-sports-confira-este-texto-e-descubra >. Acesso em: 25 de abr. 2021.

SULER, John. The *online* disinhibition effect. CyberPsychology & Behavior, v. 7, n. 3. Jul. 2004. Disponível em: <http://doi.org/10.1089/1094931041291295>. Acesso em: 05 nov. 2020.

SULER, John. Identity Management in Cyberspace. Journal of Applied Psychoanalytic Studies, v. 4, p. 455-459. out. 2002. Disponível em: <https://doi.org/10.1023/A:1020392231924>. Acesso em: 05 nov. 2020.

The pandas development team. About Pandas. PANDAS, 2020. Disponível em: < https://pandas.pydata.org/about/ >. Acesso em: 18 de mar. 2021.

THE Python Tutorial. Python Software Foundation, 2001-2021. Disponível em: < https://docs.python.org/3/tutorial/index.html >. Acesso em: 17 de mar. 2021.

Thompson, J et al. Sentiment analysis of player chat messaging in the video game StarCraft 2: Extending a lexicon-based model. Knowledge-Based Systems. v.137, p.149-162. dez. 2017. Disponível em: <https://www.sciencedirect.com/science/article/abs/pii/S0950705117304240?via%3Dihub>. Acesso em 28 out. 2020.

TU, Joe. A Daily Dosage of Toxicity in Dota 2. HCIGames, 2018. Disponível em: < https://hcigames.com/gaming-experiences/a-daily-dosage-of-toxicity-in-dota2/ >. Acesso em: 05 de maio. 2021.

WASKON, Michael. Seaborn: statistical data visualization. Seaborn, 2012-2020. Disponível em: < https://seaborn.pydata.org >. Acesso em: 25 de mar. 2021.

WHAT is NumPy? NumPy, 2021. Disponível em: < https://numpy.org/doc/stable/user/whatisnumpy.html >. Acesso em: 2 de abr. 2021.

WORD Cloud API. Word Cloud API, s/d. Disponível em: < https://wordcloudapi.com >. Acesso em 25 de nov. 2021

ZHAO, Alice, **Processamento de Linguagem Natural em Python**. YouTube. Disponível em: <https://youtu.be/xvqsFTUsOmc>. Acesso em: 12 de out. 2020. 01:51:02

APÊNDICE A – Link dos Códigos

Abaixo é mostrado o código utilizado para o desenvolvimento do estudo apresentado no trabalho. Estes códigos estão inseridos na plataforma *Google Colab*.

Os dois algoritmos de agrupamentos propostos neste trabalho foram desenvolvidos em documentos diferentes para melhor manuseio durante o desenvolvimento do trabalho. O Link 1 é referente ao algoritmo que utiliza da técnica *K-Means* enquanto o Link 2 é referente ao algoritmo que utiliza a técnica LDA.

Link 1 - K-Means

https://colab.research.google.com/drive/1qMW7C9OYg8_ppkpTH7dXPfWZdrx9qLhD?usp=sharing

Link 2 - LDA

https://colab.research.google.com/drive/1Hp6qqnVn5EQkJDbgzY01Fp9SMRNcXXwi?usp=sharing

Apêndice B – Links dos Arquivos

Abaixo serão disponibilizados os links para download dos *dataframes* utilizados durante a pesquisa, ambos ainda sem nenhum tipo de modificação ou limpeza de dados.

Para melhor visualização dos resultados, recomenda-se utilização dos arquivos no *Google Drive* ou seu upload direto a partir da plataforma do *Google Colab.* No Link 1 é apresentado o *dataframe* da base completa de chats do jogo DotA 2 utilizada para realização dos estudos. No Link 2, é apresentado o *dataframe* da base utilizada para o aprendizado do modelo para validação da performance dos algoritmos de agrupamento.

Link 1 - Base Completa

https://drive.google.com/file/d/1cYRyDTAPd3X5oIF81K3CzoknD24hmB2R/view?usp=sharing

Link 2 - Base treinamento

https://drive.google.com/file/d/1awkMTJFPG9hT7ZDEQANqbapBQl7M7htr/view?usp=sharing